

线性回归

司继春

上海对外经贸大学统计与信息学院

1 一元线性回归

在应用中，我们经常碰到所谓的「拟合 (fitting)」问题，即如果我们有一列数据 (y_i, x_i) ，我们希望使用 x_i 的线性函数形式对 y_i 进行预测，即：

$$y_i = \alpha + \beta x_i + u_i$$

其中 u_i 为预测的误差， x_i 为自变量或者解释变量，而 y_i 为因变量或者被解释变量。如果给定一个 α 和 β 的值 (α', β') ，我们可以计算残差 (residuals)：

$$e_i = y_i - \alpha' - \beta' x_i$$

为了进行拟合，我们通常希望残差 e_i 离 0 越近越好。为了度量 e_i 与 0 的距离，我们通常会使用 e_i^2 ，如果我们最小化所有样本的 e_i 的平方和，即得到了所谓的「最小二乘法 (Least squares)」：

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \sum_{i=1}^N e_i^2 = \arg \min_{\alpha, \beta} \sum_{i=1}^N (y_i - \alpha - \beta x_i)^2$$

求解上述最小化问题，即对上述目标函数求导，并令导数等于 0，得到：

$$\begin{cases} \frac{\partial \sum_{i=1}^N (y_i - \alpha - \beta x_i)^2}{\partial \alpha} = -2 \sum_{i=1}^N (y_i - \alpha - \beta x_i) = 0 \\ \frac{\partial \sum_{i=1}^N (y_i - \alpha - \beta x_i)^2}{\partial \beta} = -2 \sum_{i=1}^N (y_i - \alpha - \beta x_i) x_i = 0 \end{cases}$$

化简上述问题，得到：

$$\begin{cases} \alpha = \bar{y} - \beta \bar{x} \\ \alpha \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i y_i - \beta \sum_{i=1}^N x_i^2 \end{cases}$$

继续化简，得到：

$$\bar{x} \bar{y} - \beta \bar{x}^2 = \frac{1}{N} \sum_{i=1}^N x_i y_i - \beta \frac{1}{N} \sum_{i=1}^N x_i^2$$

因而解得：

$$\begin{cases} \hat{\beta} = \frac{\frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{x} \bar{y}}{\frac{1}{N} \sum_{i=1}^N x_i^2 - \bar{x}^2} = \frac{\sum_{i=1}^N (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^N (x_i - \bar{x})^2} \\ \hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} \end{cases}$$

以上介绍了作为拟合的一元最小二乘法，实际上回归还可以看成是简单的比较。如果以上回归方程中， x_i 只能取 0/1 两个值，令 N_0 为样本中 $x_i = 0$ 的个数， N_1 为样本中 $x_i = 1$ 的个数，同时记 \bar{y}_1 为对应于 $x_i = 1$ 的 y_i 的均值，记 \bar{y}_0 为对应于 $x_i = 0$ 的 y_i 的均值，那么：

$$\begin{aligned} \hat{\beta} &= \frac{\frac{N_1}{N} \bar{y}_1 - \frac{N_1}{N} \bar{y}}{\frac{N_1}{N} - \left(\frac{N_1}{N}\right)^2} \\ &= \frac{\bar{y}_1 - \bar{y}}{1 - \frac{N_1}{N}} \\ &= \frac{\bar{y}_1 - \left(\frac{N_1}{N} \bar{y}_1 + \frac{N-N_1}{N} \bar{y}_0\right)}{1 - \frac{N_1}{N}} \\ &= \frac{\frac{N-N_1}{N} \bar{y}_1 + \frac{N-N_1}{N} \bar{y}_0}{1 - \frac{N_1}{N}} \\ &= \bar{y}_1 - \bar{y}_0 \end{aligned}$$

因而实际上，如果 x_i 只能取 0/1 的值，那么使用 y 对 x 的回归实际上就是两组均值的比较。而同时：

$$\begin{aligned} \hat{\alpha} &= \bar{y} - \hat{\beta} \bar{x} \\ &= \frac{N_1}{N} \bar{y}_1 + \frac{N-N_1}{N} \bar{y}_0 - (\bar{y}_1 - \bar{y}_0) \frac{N_1}{N} \\ &= \frac{N-N_1}{N} \bar{y}_0 + \frac{N_1}{N} \bar{y}_0 \\ &= \bar{y}_0 \end{aligned}$$

因而 $\hat{\alpha}$ 实际就是第 0 组的均值，当 $x_i = 0$ 时，有：

$$\hat{y} = \hat{\alpha} + \hat{\beta} x_i = \hat{\alpha} = \bar{y}_0$$

而当 $x_i = 1$ 时，有：

$$\hat{y} = \hat{\alpha} + \hat{\beta} x_i = \hat{\alpha} + \hat{\beta} = \bar{y}_1$$

因而实际上，对于特定的 $x_i = 0/1$ ，其预测值就等于分组的平均值。

2 作为拟合的回归

2.1 最小二乘

以上讨论了一元线性回归，即使用一个解释变量 x 对 y 进行预测。我们还可以继续推广，即使用多个 x 对 y 进行预测：

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_{K-1} x_{i,K-1} + u_i$$

同样的，其中 u_i 为误差项， y_i 为因变量或者被解释变量，而 x_{ik} 为解释变量。为了方便起见，我们一般用向量表述上述方程：

$$y_i = x_i' \beta + u_i$$

其中：

$$x_i = \begin{pmatrix} 1 \\ x_{i1} \\ \vdots \\ x_{i,K-1} \end{pmatrix}, \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{K-1} \end{pmatrix}$$

为两个 K 维向量。为了计算方便，我们记：

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}_{N \times 1}, X = \begin{pmatrix} x_1' \\ x_2' \\ \vdots \\ x_N' \end{pmatrix}_{N \times K} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1,K-1} \\ 1 & x_{21} & \cdots & x_{2,K-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & \cdots & x_{N,K-1} \end{pmatrix}$$

因而误差项向量为：

$$e = y - X\beta = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_N \end{pmatrix}_{N \times 1}$$

与一元线性回归一样，给定一个 b ，我们可以得到残差：

$$\hat{e} = y - Xb$$

我们希望最小化残差的平方和 $\sum_{i=1}^n \hat{e}^2$ ，因而我们可以最小化：

$$\hat{\beta} = \arg \min_b \sum_{i=1}^N e_i^2 = \arg \min_b e' e = \arg \min_b (y - Xb)' (y - Xb)$$

对以上目标函数求导数并令其等于 0，可以得到：

$$\begin{aligned}\frac{\partial (y - Xb)'(y - Xb)}{\partial b} &= \frac{\partial (y'y - y'Xb - b'X'y + b'X'Xb)}{\partial b} \\ &= -X'y - X'y + 2X'Xb = 0\end{aligned}$$

解以上方程可以得到：

$$X'Xb = X'y \Rightarrow \hat{\beta} = (X'X)^{-1} X'y$$

注意以上我们使用了矩阵 $X'X$ 的逆矩阵，这就要求矩阵 $X'X$ 可逆。更进一步， $X'X$ 可逆要求矩阵 X 是列满秩的（样本量 $N > K$ ），即矩阵 X 的任何一列不能被其他列表示出来。这就排除了例如一下情况：

1. 完全相同或者成比例的 X
2. 某一个解释变量 x_{ik} 可以被其他的几个解释变量线性表示出
3. 如果存在常数项，那么加虚拟变量的时候其和不能为常数项

例如在回归分析中，我们经常加入分组的虚拟变量，即如果一个变量的取值范围为 $G_i = 1, 2, \dots, g$ ，我们经常设定如下回归：

$$y_i = \beta_0 + \tilde{x}'\tilde{\beta} + \sum_{j=1}^g \delta_j 1\{G_i = j\} + u_i$$

然而以上设定违背了矩阵 X 是列满秩的要求，必须剔除一个虚拟变量，比如：

$$y_i = \beta_0 + \tilde{x}'\tilde{\beta} + \sum_{j=1}^{g-1} \delta_j 1\{G_i = j\} + u_i$$

注意以上最大化问题的二阶导为：

$$\frac{\partial (y - X\beta)'(y - X\beta)}{\partial \beta} = 2X'X$$

为一个正定矩阵，因而以上根据一阶条件求得的解：

$$\hat{\beta} = (X'X)^{-1} X'y$$

即为原最小化问题的解。我们称以上回归为普通最小二乘回归。

2.2 最小二乘的几何性质

如果我们需要获得 y 的预测值，那么可以使用：

$$\hat{y} = X\hat{\beta} = X(X'X)^{-1}X'y$$

如果我们记 $P = X(X'X)^{-1}X'$ ，则 $\hat{y} = Py$ ，即 P 矩阵将任意一个 N 维空间向量 y 映射到其最小二乘的预测向量 \hat{y} 。注意由于：

$$\begin{aligned} P^2 &= X(X'X)^{-1}X'X(X'X)^{-1}X' \\ &= X(X'X)^{-1}X' \\ &= P \end{aligned}$$

因而矩阵 P 为实对称投影矩阵。注意如果我们取出 X 矩阵的某一行 $X_{(j)} = XI_{(j)}$ ，其中

$$I_{(j)} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \quad (j) \\ \vdots \\ 0 \end{bmatrix}$$

— 并将其使用 P 矩阵进行投影，那么：

$$\begin{aligned} PX_{(j)} &= PXI_{(j)} \\ &= X(X'X)^{-1}X'XI_{(j)} \\ &= XI_{(j)} \\ &= X_{(j)} \end{aligned}$$

即如果把 X 的某一行 $X_{(j)}$ 使用 P 进行投影，那么得到的投影仍然是 $X_{(j)}$ 本身。更进一步，对于任意的 X 的列向量的线性组合 $X\delta$ ，对其使用 P 进行投影，得到的都是 $X\delta$ 本身：

$$PX\delta = X(X'X)^{-1}X'X\delta = X\delta$$

同时，我们可以记残差为：

$$\hat{e} = y - \hat{y} = (I - P)y$$

如果我们记 $M = I - P$ ，那么 M 矩阵将任意一个 N 维空间向量 y 映射到其最




图 1: 最小二乘与投影

小二乘的残差向量 \hat{e} 。注意 M 矩阵也为幂等矩阵：

$$M^2 = (I - P)(I - P) = I - P - P + P^2 = I - P = M$$

更进一步，对于任意的 X 的列向量的线性组合 $X\delta$ ，对其使用 M 进行投影，得到的都是 0 向量：

$$MX\delta = (I - P)X\delta = X\delta - PX\delta = X\delta - X\delta = 0$$

最后，注意 $MP = (I - P)P = P - P^2 = 0$ ，同理 $PM = 0$ ，因而对于任意一个 N 维空间向量 y ，有：

$$\hat{y}'\hat{e} = (Py)'(My) = y'PM y = 0$$

即最小二乘得到的预测值向量与残差向量都是正交的。

因而我们可以把向量 y 分解为正交的两部分：

$$y = Py + My$$

且其长度满足「勾股定理」：

$$y'y = y'Py + y'My = \hat{y}'\hat{y} + \hat{e}'\hat{e}$$

2.3 拟合优度

在拟合或者预测的应用中，我们经常会关注 x 对 y 的解释能力问题。特别的，我们关注 y 的总变分（total variation）中有多少是可以被 x 解释的，其中

y 的总变分为:

$$SST = \sum_{i=1}^N (y_i - \bar{y})^2 = y' M_0 y$$

其中 $M_0 = I - \frac{1}{N} \iota \iota'$ 。注意由于 M_0 也是幂等矩阵, 因而 $y' M_0 y = (M_0 y)' M_0 y$, 因而我们可以通过分析 $M_0 y$ 来将其分解为可被 x 解释的部分和不能被 x 解释的部分:

$$M_0 y = M_0 P y + M_0 M y$$

注意如果回归方程中包含常数项, 那么 ι 为 X 矩阵的第一列, 因而:

$$M_0 M = \left(I - \frac{1}{N} \iota \iota' \right) M = M - \frac{1}{N} \iota (M \iota)' = M$$

因而上式可以化简为:

$$M_0 y = M_0 P y + M y$$

而对于 $M_0 P$, 有:

$$M_0 P = \left(I - \frac{1}{N} \iota \iota' \right) P = P - \frac{1}{N} \iota \iota'$$

注意以上矩阵仍然为实对称的幂等矩阵:

$$\begin{aligned} M_0 P M_0 P &= \left(P - \frac{1}{N} \iota \iota' \right) \left(P - \frac{1}{N} \iota \iota' \right) \\ &= P - \frac{1}{N} \iota \iota' - \frac{1}{N} \iota \iota' + \frac{1}{N^2} \iota \iota' \iota \iota' \\ &= P - \frac{1}{N} \iota \iota' - \frac{1}{N} \iota \iota' + \frac{1}{N} \iota \iota' \\ &= P - \frac{1}{N} \iota \iota' \\ &= M_0 P \end{aligned}$$

现在, 我们可以得到:

$$\begin{aligned} y' M_0 y &= (M_0 P y)' (M_0 P y) + y' M y + y' M M_0 P y + y' P M_0 M y \\ &= y' M_0 P y + y' M y \\ &= \hat{y}' M_0 \hat{y} + \hat{e}' \hat{e} \\ &= SSR + SSE \end{aligned}$$

其中

$$SSR = \hat{y}' M_0 \hat{y} = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2$$

为回归平方和，而 $SSE = \hat{e}'\hat{e}$ 为残差平方和。因而我们可以定义：

$$R^2 = \frac{SSR}{SST} = \frac{\hat{y}'M_0\hat{y}}{y'M_0y} = 1 - \frac{\hat{e}'\hat{e}}{y'M_0y}$$

R^2 度量了所谓的「拟合优度 (goodness of fit)」，即使用 x 对 y 进行预测时， x 可以解释多少部分的 y 的总变分。实际上， R^2 与方差分析有着密不可分的联系。

在实际应用中，当在回归方程中添加变量时， R^2 总是会提高的。因而为了防止过拟合，需要对 R^2 进行调整，即调整后的 R^2 ：

$$\overline{R^2} = 1 - \frac{\hat{e}'\hat{e}/(N-K)}{y'M_0y/(N-1)} = 1 - \frac{N-1}{N-K} (1 - R^2)$$

2.4 分步回归

对于回归模型：

$$y = X\beta + u$$

如果我们把 X 分为两部分变量： X_1, X_2 ，那么：

$$y = X_1\beta_1 + X_2\beta_2 + u$$

如果对以上方程求解最小二乘，我们可以得到如下的一阶条件：

$$\begin{bmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} X_1'y \\ X_2'y \end{bmatrix}$$

解以上方程，即：

$$\begin{cases} X_1'X_1\hat{\beta}_1 + X_1'X_2\hat{\beta}_2 = X_1'y \\ X_2'X_1\hat{\beta}_1 + X_2'X_2\hat{\beta}_2 = X_2'y \end{cases}$$

由第一个式子可以得到：

$$\hat{\beta}_1 = (X_1'X_1)^{-1} (X_1'y - X_1'X_2\hat{\beta}_2)$$

带入第二个式子：

$$\begin{aligned} X_2'X_2\hat{\beta}_2 &= X_2'y - X_2'X_1\hat{\beta}_1 \\ &= X_2'y - X_2'X_1(X_1'X_1)^{-1} (X_1'y - X_1'X_2\hat{\beta}_2) \\ &= X_2'y - X_2'X_1(X_1'X_1)^{-1} X_1'y + X_2'X_1(X_1'X_1)^{-1} X_1'X_2\hat{\beta}_2 \end{aligned}$$

记 $P_1 = X_1 (X_1' X_1)^{-1} X_1'$ ，则上式可以简记为：

$$X_2' X_2 \hat{\beta}_2 - X_2' P_1 X_2 \hat{\beta}_2 = X_2' y - X_2' P_1 y$$

整理得：

$$X_2' (I - P_1) X_2 \hat{\beta}_2 = X_2' (I - P_1) y$$

记 $M_1 = I - P_1$ ，那么：

$$\hat{\beta}_2 = (X_2' M_1 X_2)^{-1} X_2' M_1 y$$

同理：

$$\hat{\beta}_1 = (X_1' M_2 X_1)^{-1} X_1' M_2 y$$

注意实际上 $M_2 X_1$ 即使用 X_1 的每一个列向量对 X_2 做回归，得到的残差所组成的矩阵，因而如果记：

$$\begin{cases} \hat{e}_{X_1} = M_2 X_1 \\ \hat{e}_y = M_2 y \end{cases}$$

那么：

$$\begin{aligned} \hat{\beta}_1 &= (X_1' M_2 X_1)^{-1} X_1' M_2 y \\ &= (\hat{e}_{X_1}' \hat{e}_{X_1})^{-1} \hat{e}_{X_1}' \hat{e}_y \end{aligned}$$

即如果我们对解释变量进行分组， $X = (X_1, X_2)$ ，那么 X_1 的系数等价于：

1. 使用对 X_1 对 X_2 做回归，得到残差 \hat{e}_{X_1}
2. 使用 y 对 X_2 做回归，得到残差 \hat{e}_y
3. 使用 \hat{e}_y 对 \hat{e}_{X_1} 做回归，得到系数 $\hat{\beta}_1$

以上步骤与直接进行最小二乘估计是等价的。

3 其他拟合方法：非参数与半参数回归

以上线性回归可以使用 x 对 y 进行拟合，然而使用了非常强的假设，即 x 和 y 之间存在着线性关系，然而这一假设并不一定满足。很多时候我们希望在没有函数形式假定的情况下使用 x 对 y 进行拟合，这就诞生了非参数回归。为了介绍非参数回归，我们先从密度函数的估计入手。

3.1 核密度估计

首先我们考虑对于随机变量 x 的密度函数的估计。为了便于叙述，我们首先考虑一元随机变量 x 的密度估计。

考虑一下密度函数的概念，密度函数就是分布函数的一阶导数。一般情况下，我们可以使用经验分布函数（empirical distribution function）对分布函数进行估计：

$$\hat{F}(t) = \frac{1}{N} \sum_{i=1}^N 1\{x_i \leq t\}$$

然而以上估计出的分布函数不可导，所以我们不能使用其对密度函数进行估计。

考虑导数的定义，如果假设分布函数连续可微，那么：

$$f(t) = F'(t) = \lim_{\Delta t \rightarrow 0} \frac{F(t + \Delta t) - F(t - \Delta t)}{2\Delta t}$$

如果我们使用经验分布函数 $\hat{F}(t)$ 代替上式中的分布函数 $F(t)$ ，同时给定一个固定的 $\Delta t = h$ ，有：

$$\hat{f}(t) = \frac{\hat{F}(t + h) - \hat{F}(t - h)}{2h}$$

而根据经验分布函数 \hat{F} 的定义，以上估计等价于：

$$\begin{aligned} \hat{f}(t) &= \frac{\#\{x_i \in (t - h, t + h)\}}{2hN} \\ &= \frac{1}{Nh} \sum_{i=1}^N \frac{1\{t - h \leq x_i \leq t + h\}}{2} \\ &= \frac{1}{Nh} \sum_{i=1}^N \frac{1}{2} 1\left\{\left|\frac{x_i - t}{h}\right| \leq 1\right\} \end{aligned}$$

即，给定一个 t ，选取一个 h ，样本落在在邻域 $(t - h, t + h)$ 中的比例即可以当做是密度函数的一个近似估计。

注意在以上的替代过程中，导数的定义要求 $h \rightarrow 0$ ，而我们在实际操作过程中我们不可能让 $h = 0$ ，所以必须选取一个正的 h 。然而 h 选取的太大，则会违背导数的定义，导致估计的偏差很大；如果太小，那么在一个邻域内样本量可能会非常小，甚至没有观测，导致估计的方差很大。这也就是非参数估计里面的 bias-variance tradeoff。实际使用中，理论上存在着一个能够平衡偏差和方差的最优的 h 。我们通常把 h 成为窗宽（bandwidth）。

注意以上的密度函数是不光滑的。观察以上式子，如果记 $K_0(u) = \frac{1}{2} 1\{|u| \leq 1\}$ ，

那么：

$$\begin{aligned}\int_{\mathbb{R}} \hat{f}(t) dt &= \int_{\mathbb{R}} \frac{1}{Nh} \sum_{i=1}^N K_0\left(\frac{x_i - t}{h}\right) dt \\ &= \frac{1}{Nh} \sum_{i=1}^N \int_{\mathbb{R}} K_0\left(\frac{x_i - t}{h}\right) dt \\ &= \frac{1}{N} \sum_{i=1}^N \int_{\mathbb{R}} K_0(u) du\end{aligned}$$

因而如果 $\int_{\mathbb{R}} K_0(u) du = 1$ ，那么估计出的密度函数等于 1。

因而我们经常会替换其中的 $K_0(u) = \frac{1}{2}1\{|u| \leq 1\}$ 为常用的连续随机变量的密度函数 $K(\cdot)$ （比如正态分布密度函数），从而得到密度函数的一个光滑的估计。我们称 $K(\cdot)$ 为核函数（kernel function）。

如果我们用正态分布的密度函数对 x 的密度进行估计，那么：

$$\hat{f}(t) = \frac{1}{Nh} \sum_{i=1}^N K\left(\frac{x_i - t}{h}\right)$$

其中 $K(\cdot)$ 取为正态分布的密度函数。

以上讨论的是一元随机变量 x 的核密度估计，以上方法还可以进行进一步推广。如果 $x_i = (x_{i1}, \dots, x_{ik})'$ 为 k 维的随机样本， $i = 1, 2, \dots, N$ ，那么核密度估计为：

$$\hat{f}(t) = \frac{1}{N \cdot h_1 \cdot \dots \cdot h_k} \sum_{i=1}^N K_1\left(\frac{x_{i1} - t_1}{h_1}\right) \cdot \dots \cdot K_k\left(\frac{x_{ik} - t_k}{h_k}\right)$$

3.2 非参数回归

如果我们有数据 (y_i, x_i') ，我们希望使用 x_i 拟合 y_i ，如果我们有理由认为 y_i 与 x_i 之间存在线性关系，那么自然可以使用线性回归：

$$y_i = x_i' \beta + u_i$$

对以上函数进行拟合。然而如果我们并不知道函数形式，那么更一般的方法是对 x 与 y 之间的函数关系不多任何假设：

$$y_i = g(x_i) + u_i$$

其中 $u_i = y_i - \mathbb{E}(y_i|x_i)$ 。

然而如果对函数形式不做任何假设，以上估计过程就变得十分困难。在此我们需要一些平滑性的假设，假设 $g(x_i)$ 为一个足够平滑的函数。在此基础上，

观察到：

$$\begin{aligned}\mathbb{E}(y_i|x_i) &= \int_{\mathbb{R}} y f(y|x) dy \\ &= \int_{\mathbb{R}} y \frac{f(x,y)}{f_X(x)} dy \\ &= \frac{\int_{\mathbb{R}} y f(x,y) dy}{f_X(x)}\end{aligned}$$

我们可以通过使用核密度估计替代以上方程中的两个密度函数，对 $\mathbb{E}(y_i|x_i)$ 进行估计。

由于：

$$\hat{f}(x,y) = \frac{1}{N h_y h} \sum_{i=1}^N K\left(\frac{y-y_i}{h_y}\right) K\left(\frac{x-x_i}{h}\right)$$

而

$$f_X(x) = \frac{1}{N h} \sum_{i=1}^N K\left(\frac{x_i-x}{h}\right)$$

因而：

$$\begin{aligned}\frac{\int_{\mathbb{R}} y f(x,y) dy}{f_X(x)} &= \frac{\int_{\mathbb{R}} y \frac{1}{N h_y h} \sum_{i=1}^N K\left(\frac{y-y_i}{h_y}\right) K\left(\frac{x-x_i}{h}\right) dy}{\frac{1}{N h} \sum_{i=1}^N K\left(\frac{x_i-x}{h}\right)} \\ &= \frac{\frac{1}{h_y} \sum_{i=1}^N K\left(\frac{x-x_i}{h}\right) \int_{\mathbb{R}} y K\left(\frac{y-y_i}{h_y}\right) dy}{\sum_{i=1}^N K\left(\frac{x_i-x}{h}\right)} \\ &= \frac{\frac{1}{h_y} \sum_{i=1}^N K\left(\frac{x-x_i}{h}\right) \int_{\mathbb{R}} (h_y u + y_i) K(u) h_y du}{\sum_{i=1}^N K\left(\frac{x_i-x}{h}\right)} \\ &= \frac{\frac{1}{h_y} \sum_{i=1}^N K\left(\frac{x-x_i}{h}\right) [h_y^2 \int_{\mathbb{R}} u K(u) du + h_y y_i \int_{\mathbb{R}} K(u) du]}{\sum_{i=1}^N K\left(\frac{x_i-x}{h}\right)} \\ &= \frac{\sum_{i=1}^N K\left(\frac{x-x_i}{h}\right) y_i \int_{\mathbb{R}} K(u) du}{\sum_{i=1}^N K\left(\frac{x_i-x}{h}\right)} \\ &= \frac{\sum_{i=1}^N K\left(\frac{x-x_i}{h}\right) y_i}{\sum_{i=1}^N K\left(\frac{x_i-x}{h}\right)}\end{aligned}$$

其中我们假设了使用了对称的核函数，因而 $\int_{\mathbb{R}} u K(u) du = 0$ 。以上即是非参数回归的表达式，即：

$$\hat{\mathbb{E}}(y_i|x_i = x) = \frac{\sum_{i=1}^N K\left(\frac{x-x_i}{h}\right) y_i}{\sum_{i=1}^N K\left(\frac{x_i-x}{h}\right)}$$

实际上，以上非参数回归可以看成是使用 $K\left(\frac{x-x_i}{h}\right)$ 作为权重的滑动平均，给予

x 距离近的点以更多的权重，而距离 x 远的点以更小的权重，如此进行加权平均，即得到了非参数回归。

注意非参数回归也有其应用局限。首先， x 的维数不能太大，实际上非参数回归仅仅适合维数比较小的情况下使用。对于任何一个点 $x_i = x$ 处，周围可以用以滑动平均的点随着维数变大迅速减少，因而其大样本性质随着维数增大也会逐渐变差。

其次，非参数回归不能做外延预测，即不能做超过数据集范围的预测。实际上，即使没有超过数据集 x_i 的取值范围，在 x_i 的边界处，预测的效果也会大打折扣。

由于非参数回归的这些缺点，我们可以将参数回归和非参数回归结合，得到半参数回归。即，如果我们有两部分自变量 x_i 和 w_i ，我们可以对 x_i 进行参数假设，而对 w_i 不做任何参数假设，即设定模型：

$$y_i = x_i' \beta + g(w_i) + u_i$$

注意到，对上市两边对 w_i 求条件期望，由于：

$$\mathbb{E}(y_i | w_i) = \mathbb{E}(x_i | w_i)' \beta + g(w_i)$$

因而：

$$y_i - \mathbb{E}(y_i | w_i) = [x_i - \mathbb{E}(x_i | w_i)]' \beta + u_i$$

因而我们可以使用 y_i 和 x_i 分别对 w_i 做非参数回归，得到残差后使用得到的残差做线性回归，即可得到 β 的估计。