

# 线性回归

司继春

上海对外经贸大学统计与信息学院

## 1 线性回归

### 1.1 线性回归的估计

以上我们从拟合和几何的角度讨论了线性回归。而在计量经济学中，回归的目的在于解释而非预测，即关心所谓的因果效应 (Causal effects)。比如，在计量经济学中，我们可能关心受教育程度对未来收入的影响，其目的不是为了使用受教育程度预测个人的收入，而是关心受教育程度是不是导致了个人可以获得更高的收入。为了得到因果效应，我们就必须在模型中做一些假设。

在上面的讨论中，我们通过最小化：

$$\hat{\beta} = \arg \min_b \sum_{i=1}^N e_i^2 = \arg \min_b e'e = \arg \min_b (y - Xb)'(y - Xb)$$

得到了多元线性回归。在这里，最小二乘法强调的是拟合。而如果我们希望得到所谓的因果效应，最关键的假设是所谓的外生性 (Exogeneity) 假设，即对于回归方程：

$$y_i = x_i' \beta + u_i$$

外生性假设即：

$$\mathbb{E}(u_i | x_i) = 0$$

即回归方程中的解释变量与误差项无关。

然而现实中很多应用都不满足这一假设。比如在以上受教育程度的例子中，尽管我们可以使用受教育程度预测个人的收入，但是如果简单使用线性回归解释个人的收入，现实数据可能并不满足以上的外生性假设。比如，个人的能力 (*ability*) 可能会影响个人能否上大学，同时也会影响其毕业之后的收入。即，能上大学的个人普遍来说能力更强，可能即使他不上大学，其收入也比较高。我们可以使用如下方程表示：

$$income_i = \gamma \cdot edu_i + x_i' \beta + ability_i + \epsilon_i$$

其中  $x_i$  为其他外生的控制变量。现实问题是，尽管能力对收入有影响，然而能

力是不可观测的，因而我们实际可以做的回归是：

$$income_i = \gamma \cdot edu_i + x_i' \beta + u_i$$

其中  $u_i = ability_i + \epsilon_i$ 。由于教育程度与能力相关，因而  $Cov(ability_i, edu_i) \neq 0$ ，从而  $Cov(u_i, edu_i) \neq 0$ ，因而  $E(u_i|x_i) \neq 0$ ，外生性假设无法满足。

当外生性假设无法满足时，我们需要一些其他的计量方法进行处理，比如下面将要介绍的工具变量法。现在，我们假设外生性假设成立，并在此基础上讨论参数的估计和推断问题。

对于回归方程：

$$y_i = x_i' \beta + u_i$$

其中  $x_i$  为  $k$  维向量，代表解释变量； $\beta$  为解释变量的系数； $u_i$  为误差项。如果外生性假设成立，即  $E(u_i|x_i) = 0$ ，那么根据条件期望的性质，必然有：

$$E(x_i u_i) = E[E(x_i u_i | x_i)] = E[x_i E(u_i | x_i)] = E[x_i \cdot 0] = 0$$

因而外生性假设保证了误差项  $u_i$  与  $x_i$  之间是不相关的。进而，我么可以使用矩估计的方法对  $\beta$  进行估计。注意到不可观测的  $u_i$  可以写为：

$$u_i = y_i - x_i' \beta$$

从而：

$$E[(y_i - x_i' \beta) x_i] = 0$$

注意由于  $u_i = y_i - x_i' \beta$  为标量，而  $x_i$  为  $K \times 1$  的向量，因而以上方程实际上包含着  $K$  个矩条件。对以上方程进行整理，得到：

$$E(x_i x_i') \beta = E(x_i y_i)$$

如果假设  $E(x_i x_i')$  可逆，那么：

$$\beta = [E(x_i x_i')]^{-1} E(x_i y_i)$$

根据矩估计的思想，如果我们分别使用均值：

$$\frac{1}{N} \sum_{i=1}^N x_i x_i' \text{ 和 } \frac{1}{N} \sum_{i=1}^N x_i y_i$$

代替总体均值，那么就得到了以上问题的矩估计：

$$\hat{\beta} = \left[ \frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i = \left[ \sum_{i=1}^N x_i x_i' \right]^{-1} \sum_{i=1}^N x_i y_i$$

注意以上估计实际上就是最小二乘估计:  $\hat{\beta} = (X'X)^{-1} X'Y$ 。

以上矩估计是在外生性假设的基础之上得到的。如果在外生性假设上更进一步, 不仅假设  $\mathbb{E}(u_i|x_i) = 0$ , 同时假设  $u_i|x_i$  的分布, 比如正态分布, 我们还可以得到  $\beta$  的极大似然估计。如果假设  $u_i|x_i \sim N(0, \sigma^2)$ , 那么  $y_i|x_i \sim N(x_i'\beta, \sigma^2)$ , 因而其条件极大似然函数为:

$$L(y|x) = \sum_{i=1}^N \left[ -\ln(2\pi) - \ln \sigma - \frac{(y_i - x_i'\beta)^2}{\sigma^2} \right]$$

最大化以上似然函数, 实际上等价于最小化  $\sum_{i=1}^N (y_i - x_i'\beta)^2$ , 即最小二乘的目标函数, 因而在正态分布的假设下, 使用条件极大似然方法得到的  $\beta$  的估计同样也是最小二乘估计量。

## 1.2 回归系数的解释

在以上的回归方程中, 由于我们假设了  $\mathbb{E}(u_i|x_i) = 0$ , 那么  $y_i$  给定  $x_i$  的条件期望:

$$\mathbb{E}(y_i|x_i) = x_i'\beta$$

其中系数可以理解为条件期望  $\mathbb{E}(y_i|x_i)$  对  $x_i$  的偏导, 即:

$$\beta_j = \frac{\partial \mathbb{E}(y_i|x_i)}{\partial x_{ij}}$$

即系数  $\beta_j$  可以解释为变量  $x_{ij}$  对条件期望  $\mathbb{E}(y_i|x_i)$  的偏效应 (partial effects)。使用平均偏效应有助于我们解释估计所得到的系数的含义, 比如如下几种特殊情形:

1. 若  $y_i = \beta_1 \cdot x_{i1} + x_i'\beta + u_i$ , 那么偏效应:

$$\frac{\partial \mathbb{E}(y_i|x_{i1}, x_i)}{\partial x_{i1}} = \beta_1$$

即  $x_{i1}$  每增加一单位, 则  $y_i$  平均增加  $\beta_1$  单位。

2. 若  $y_i = \beta_1 \cdot x_{i1} + \beta_2 x_{i1}^2 + x_i'\beta + u_i$ , 那么偏效应:

$$\frac{\partial \mathbb{E}(y_i|x_{i1}, x_i)}{\partial x_{i1}} = \beta_1 + 2\beta_2 x_{i1}$$

那么意味着  $x_{i1}$  对  $y_i$  的影响是非线性的, 如果  $\beta_2 > 0$ , 那么  $x_{i1}$  对  $y_i$  的影响随着  $x_{i1}$  的增加而增加。

3. 若  $y_i = \beta_1 \cdot x_{i1} + \beta_2 x_{i1} x_{i2} + \beta_3 x_{i2} + x_i'\beta + u_i$ , 那么偏效应:

$$\frac{\partial \mathbb{E}(y_i|x_{i1}, x_{i2}, x_i)}{\partial x_{i1}} = \beta_1 + \beta_2 x_{i2}$$

那么意味着  $x_{i1}$  对  $y_i$  的影响收到另外一个变量  $x_{i2}$  的影响, 如果  $\beta_2 > 0$ , 那么  $x_{i1}$  对  $y_i$  的影响随着  $x_{i2}$  的增加而增加。

4. 若  $\ln y_i = \beta_1 \cdot \ln x_{i1} + x'_{i2}\beta + u_i$ , 那么偏效应:

$$\frac{\partial \mathbb{E}(\ln y_i | x_{i1}, x_i)}{\partial \ln x_{i1}} = \beta_1$$

注意由于  $\partial \ln y_i = \frac{1}{y_i} \partial y_i$ , 同理  $\partial \ln x_{i1} = \frac{1}{x_{i1}} \partial x_{i1}$ , 即百分比变动, 因而  $\beta_1$  可以解释为当  $x_{i1}$  增加 1% 时,  $y_i$  增加的百分比变动的期望, 即弹性。注意由于

$$\mathbb{E}(\ln y_i | x_{i1}, x_i) \neq \ln \mathbb{E}(y_i | x_{i1}, x_i)$$

因而  $\beta_1$  不能被解释为当  $x_{i1}$  增加 1% 时条件期望变动的百分比。

注意以上 3、4 两个例子中, 得到的偏效应都是一个变量的函数, 即  $x_{i1}$  对  $y_i$  的影响不是一个常数。在这种情况下, 我们经常会关心所谓的平均偏效应 (Average partial effects), 即  $x_{i1}$  对  $y_i$  的影响的均值:

$$\mathbb{E}\left(\frac{\partial \mathbb{E}(y_i | x_i)}{\partial x_{ij}}\right)$$

例如在 3 中, 平均偏效应为:

$$\mathbb{E}\left[\frac{\partial \mathbb{E}(y_i | x_{i1}, x_{i2}, x_i)}{\partial x_{i1}}\right] = \beta_1 + \beta_2 \mathbb{E}(x_{i2})$$

在实践中, 对于有交叉项、平方项存在的回归中, 我们经常会对变量去平均。例如在 3 的回归方程中:

$$y_i = \beta_1 \cdot x_{i1} + \beta_2 x_{i1} x_{i2} + \beta_3 x_{i2} + x'_{i2}\beta + u_i$$

令  $x_{i1}^* = x_{i1} - \bar{x}_1$ , 同时令  $x_{i2}^* = x_{i2} - \bar{x}_2$ , 我们经常使用回归:

$$y_i = \beta_1 \cdot x_{i1}^* + \beta_2 x_{i1}^* x_{i2}^* + \beta_3 x_{i2}^* + x'_{i2}\beta + u_i$$

如此, 我们可以得到平均偏效应为:

$$\mathbb{E}\left[\frac{\partial \mathbb{E}(y_i | x_{i1}^*, x_{i2}^*, x_i)}{\partial x_{i1}^*}\right] = \beta_1 + \beta_2 \mathbb{E}(x_{i2}^*) = \beta_1$$

即去平均处理后, 得到的回归系数即为平均偏效应。

### 1.3 线性回归的小样本统计性质

在这里我们将讨论线性回归的小样本统计性质, 包括无偏性即参数估计  $\hat{\beta}$  的小样本分布。

首先对于无偏性，由于：

$$\begin{aligned}\hat{\beta} &= (X'X)^{-1} X'Y \\ &= (X'X)^{-1} X' (X'\beta + u) \\ &= \beta + (X'X)^{-1} X'u\end{aligned}$$

其中

$$u = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_N \end{bmatrix}$$

为误差项向量。从而：

$$\begin{aligned}\mathbb{E}(\hat{\beta}) &= \beta + \mathbb{E}\left((X'X)^{-1} X'u\right) \\ &= \beta + \mathbb{E}\left[\mathbb{E}\left((X'X)^{-1} X'u|X\right)\right] \\ &= \beta + \mathbb{E}\left[(X'X)^{-1} X'\mathbb{E}(u|X)\right] \\ &= \beta\end{aligned}$$

因而在外生性假设下，最小二乘估计是真实参数  $\beta$  的无偏估计。

此外我们还可以计算最小二乘估计  $\hat{\beta}$  的方差。注意到由于  $\hat{\beta} - \beta = (X'X)^{-1} X'u$ ，因而  $\hat{\beta}$  的条件协方差矩阵为：

$$\begin{aligned}\text{Var}(\hat{\beta}|X) &= \mathbb{E}\left[(\hat{\beta} - \beta)(\hat{\beta} - \beta)'|X\right] \\ &= \mathbb{E}\left[(X'X)^{-1} X'uu'X(X'X)^{-1}|X\right] \\ &= (X'X)^{-1} X'\mathbb{E}[uu'|X]X(X'X)^{-1}\end{aligned}$$

在同方差 (homoskedasticity) 假定下，即假定  $\text{Var}(u_i|x_i) = \sigma^2$ ，以及假定不存在自相关，即  $\text{Cov}(u_i, u_j) = 0$  的条件下，那么

$$\mathbb{E}(uu'|X) = \sigma^2 I$$

则上式可以化简为：

$$\begin{aligned}\text{Var}(\hat{\beta}|X) &= (X'X)^{-1} X'\mathbb{E}[uu'|X]X(X'X)^{-1} \\ &= (X'X)^{-1} X'\sigma^2 IX(X'X)^{-1} \\ &= \sigma^2 (X'X)^{-1}\end{aligned}$$

实际上我们可以证明, 在  $\beta$  的所有线性无偏估计量中, 最小二乘估计量是方差最小的估计量。不妨假设存在另外一个  $\beta$  的无偏估计量  $\tilde{\beta} = Cy$ , 由于无偏性, 因而:

$$\mathbb{E}(\tilde{\beta}) = \mathbb{E}(Cy) = \mathbb{E}[C(X\beta + u)] = \mathbb{E}(CX)\beta + \mathbb{E}(Cu)$$

上式这意味着  $CX = I$ 。注意  $\tilde{\beta}$  的方差为:

$$\text{Var}(\tilde{\beta}) = \sigma^2 CC'$$

因而其两个估计量方差之逆的差为:

$$\begin{aligned} \text{Var}(\hat{\beta})^{-1} - \text{Var}(\tilde{\beta})^{-1} &= \frac{1}{\sigma^2} [X'X - (CC')^{-1}] \\ &= \frac{1}{\sigma^2} [X'X - X'C(CC')^{-1}CX] \\ &= \frac{1}{\sigma^2} X' [I - C(CC')^{-1}C] X \end{aligned}$$

注意到由于矩阵  $I - C(CC')^{-1}C$  为幂等矩阵, 因而一定是半正定矩阵, 从而:

$$\text{Var}(\hat{\beta})^{-1} - \text{Var}(\tilde{\beta})^{-1} \geq 0$$

从而  $\text{Var}(\hat{\beta}) \leq \text{Var}(\tilde{\beta})$ 。正是由于以上性质, 我们称最小二乘估计量  $\hat{\beta}$  为**最优线性无偏估计量** (**Best linear unbiased estimator, BLUE**)。

在推断中, 我们需要计算  $\hat{\beta}$  的无条件方差, 即:

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \mathbb{E}(\text{Var}(\hat{\beta}|X)) + \text{Var}(\mathbb{E}(\hat{\beta}|X)) \\ &= \sigma^2 \mathbb{E}(X'X) + \text{Var}(\beta) \\ &= \sigma^2 \mathbb{E}(X'X) \end{aligned}$$

由于  $\sigma^2$  未知, 因而我们需要对  $\sigma^2$  进行估计。记残差:

$$\hat{e} = Y - X\hat{\beta} = MY = M(X'\beta + u) = Mu$$

从而残差平方和为:

$$\hat{e}'\hat{e} = u'Mu$$

其期望:

$$\begin{aligned}
 \mathbb{E}(\hat{e}'\hat{e}) &= \mathbb{E}(u'Mu) \\
 &= \mathbb{E}[\text{tr}(u'Mu)] \\
 &= \mathbb{E}[\text{tr}(Mu u')] \\
 &= \text{tr}[\mathbb{E}(Mu u')] \\
 &= \text{tr}[\mathbb{E}(\mathbb{E}(Mu u'|X))] \\
 &= \text{tr}[\mathbb{E}(M\mathbb{E}(u u'|X))] \\
 &= \text{tr}[\mathbb{E}(\sigma^2 M)] \\
 &= \sigma^2 \mathbb{E}\left(\text{tr}\left(I - X(X'X)^{-1}X'\right)\right) \\
 &= \sigma^2 \mathbb{E}\left(\text{tr}(I) - \text{tr}\left(X(X'X)^{-1}X'\right)\right) \\
 &= \sigma^2 \left(N - \text{tr}\left((X'X)^{-1}X'X\right)\right) \\
 &= \sigma^2 (N - K)
 \end{aligned}$$

因而:

$$\sigma^2 = \frac{\mathbb{E}(\hat{e}'\hat{e})}{N - K}$$

从而我们可以使用残差平方和对  $\sigma^2$  进行估计, 即使用:

$$s^2 = \frac{\hat{e}'\hat{e}}{N - K}$$

对  $\sigma^2$  进行估计。

以上我们得到了最小二乘估计量的最优无偏线性估计量的性质, 进而讨论了误差项方差的估计, 然而对于统计推断来说, 我们还需要估计量的抽样分布。然而在对误差项  $u$  不做任何假定的情况下, 小样本条件下我们不能得到估计量的精确分布, 因而必须对  $u$  的分布做进一步的假设。一个常用的假设是正态性假设, 即假设误差项  $u_i$  为独立同分布的正态分布,  $u_i \sim N(0, \sigma^2)$ , 或者  $u \sim N(0, \sigma^2 I)$ 。

在正态性假设基础之上, 由于  $\hat{\beta} - \beta = (X'X)^{-1}X'u$ , 因而:

$$\hat{\beta}|X \sim N\left(\beta, \sigma^2 (X'X)^{-1}\right)$$

即最小二乘估计量  $\hat{\beta}$  服从联合正态分布。进而, 单独某一个系数的分布也是正态分布, 即:

$$\hat{\beta}_j|X \sim N\left(\beta_j, \sigma^2 (X'X)^{-1}_{jj}\right)$$

其中  $(X'X)^{-1}_{jj}$  代表矩阵  $(X'X)^{-1}$  的第  $j$  行第  $j$  列的元素值。进而, 对于原假

设：

$$H_0 : \beta_j = b$$

我们可以使用统计量

$$t_j = \frac{\hat{\beta}_j - b}{\sqrt{s^2 (X'X)^{-1}_{jj}}} \sim t(N - K)$$

即以上统计量服从自由度为  $N - k$  的  $t$  分布。以上统计量可以用来对单个系数进行假设检验。

如果我们希望检验是否所有的  $\beta_j$  都等于 0 (除常数项)，那么可以使用  $F$  检验。不失一般性，假设截距项为  $\beta_1$ ，那么原假设：

$$H_0 : \beta_2 = \beta_3 = \cdots = \beta_k = 0$$

可以使用统计量：

$$F = \frac{R^2 / (K - 1)}{(1 - R^2) / (N - K)} \sim F(k - 1, N - K)$$

在原假设条件下， $R^2 = 0$ ，因而只需要检验  $F = 0$  即可。实际上，由于：

$$R^2 = \frac{\hat{y}' M_0 \hat{y}}{y' M_0 y} = 1 - \frac{\hat{e}' \hat{e}}{y' M_0 y}$$

因而

$$F = \frac{\hat{y}' M_0 \hat{y} / (K - 1)}{\hat{e}' \hat{e} / (N - K)}$$

其中：

$$M_0 \hat{y} = M_0 P y = M_0 (X \beta + P u)$$

在原假设条件下， $X \beta = \beta_1 \iota$ ，而  $M_0 \iota = (I - \frac{1}{N} \iota \iota') \iota = \iota - \iota = 0$ ，因而在原假设条件下， $M_0 \hat{y} = M_0 P u$ 。而由于：

$$M_0 P = \left( I - \frac{1}{N} \iota \iota' \right) P = P - \frac{1}{N} \iota \iota'$$

为实对称幂等矩阵，且  $\text{tr}(M_0 P) = \text{tr}(P) - \text{tr}(\frac{1}{N} \iota \iota') = K - 1$ ，如果  $u \sim N(0, \sigma^2 I)$ ，那么：

$$\frac{1}{\sigma} \hat{y}' M_0 \hat{y} = \frac{1}{\sigma} u' M_0 P u \sim \chi^2(K - 1)$$



同理  $\hat{e} = Mu$ ,  $\text{tr}(M) = \text{tr}(I - P) = N - K$ , 因而:

$$\frac{1}{\sigma} \hat{e}' \hat{e} = \frac{1}{\sigma} u' Mu \sim \chi^2(N - K)$$

最后, 注意到  $M_0 P \cdot M = M_0 (PM) = 0$ , 因而  $\frac{1}{\sigma} \hat{y}' M_0 \hat{y}$  与  $\frac{1}{\sigma} \hat{e}' \hat{e}$  为独立的  $\chi^2$  分布, 从而

$$F = \frac{\hat{y}' M_0 \hat{y} / (K - 1)}{\hat{e}' \hat{e} / (N - K)} \sim F(K - 1, N - K)$$

如果我们即不是针对单个系数进行检验, 也不是针对所有的系数做联合检验, 而是针对一个系数之间的线性关系做检验, 即原假设为:

$$H_0 : R\beta + q = 0$$

其中  $R$  为  $r \times K$  维的矩阵,  $q$  为  $r \times 1$  维向量。例如如果我们需要检验  $\beta_2 + \beta_3 = 1$ , 同时  $\beta_1 = 0$ ,  $K = 4$ , 即原假设为:

$$H_0 : \beta_2 + \beta_3 = 1, \beta_1 = 0$$

那么可以取

$$R = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 \end{bmatrix}, q = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

在这种情况下, 我们可以使用 Wald 检验。注意到, 由于

$$\hat{\beta}|X \sim N(\beta, \sigma^2 (X'X)^{-1})$$

因而

$$R\hat{\beta} + q|X \sim N(R\beta + q, \sigma^2 R(X'X)^{-1} R')$$

从而:

$$(R\hat{\beta} + q)' [\sigma^2 R(X'X)^{-1} R']^{-1} (R\hat{\beta} + q) \sim \chi^2(r)$$

然而注意到由于  $\sigma^2$  是未知的, 因而需要使用  $s^2$  进行替代。下面我们将会看到,  $s^2 = \sigma^2 + o_p(1)$ , 因而如此替代并不会改变以上统计量的大样本分布, 即仍然可以使用

$$(R\hat{\beta} + q)' [s^2 R(X'X)^{-1} R']^{-1} (R\hat{\beta} + q) \stackrel{a}{\sim} \chi^2(r)$$

进行假设检验。

## 1.4 方差分析

## 1.5 线性回归的大样本统计性质

下面我们来讨论最小二乘估计量的大样本性质。首先我们讨论最小二乘估计量的一致性。注意到最小二乘估计量为：

$$\hat{\beta} = \left[ \frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i$$

式中出现了两个平均，我们可以分别对以上两部分使用大数定律。在一定比较宽松的假定下，根据大数定律，有：

$$\frac{1}{N} \sum_{i=1}^N x_i x_i' \xrightarrow{P} \mathbb{E}(x_i x_i')$$

以及：

$$\frac{1}{N} \sum_{i=1}^N x_i y_i \xrightarrow{P} \mathbb{E}(x_i y_i) = \mathbb{E}(x_i (x_i' \beta + u)) = \mathbb{E}(x_i x_i') \beta$$

由于矩阵的逆也是连续函数，因而如果  $[\mathbb{E}(x_i x_i')]^{-1}$  存在，那么：

$$\hat{\beta} = \left[ \frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i \xrightarrow{P} [\mathbb{E}(x_i x_i')]^{-1} \mathbb{E}(x_i x_i') \beta = \beta$$

因而一致性成立。

此外，我们还可以建立  $\hat{\beta}$  的渐进正态性。注意到由于

$$\hat{\beta} = \left[ \frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i = \beta + \left[ \frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i u_i$$

根据大数定律，我们关注  $\sqrt{N}(\hat{\beta} - \beta)$  的渐进分布。由于：

$$\sqrt{N}(\hat{\beta} - \beta) = \left[ \frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{\sqrt{N}} \sum_{i=1}^N x_i u_i$$

其中第一部分可以根据大数定律，得到  $\left[ \frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \xrightarrow{P} [\mathbb{E}(x_i x_i')]^{-1}$ ，而第二部分可以使用中心极限定理：

$$\frac{1}{\sqrt{N}} \sum_{i=1}^N x_i u_i \stackrel{a}{\sim} N(\mathbb{E}(x_i u_i), \text{Var}(x_i u_i))$$

由于  $\mathbb{E}(x_i u_i) = 0$ ,  $\text{Var}(x_i u_i) = \mathbb{E}(u_i^2 x_i x_i')$ , 因而:

$$\frac{1}{\sqrt{N}} \sum_{i=1}^N x_i u_i \stackrel{a}{\sim} N(0, \mathbb{E}(u_i^2 x_i x_i'))$$

综上, 我们可以得到:

$$\sqrt{N}(\hat{\beta} - \beta) \stackrel{a}{\sim} N(0, [\mathbb{E}(x_i x_i')]^{-1} \mathbb{E}(u_i^2 x_i x_i') [\mathbb{E}(x_i x_i')]^{-1})$$

更进一步, 如果我们假设  $u_i$  为独立同分布, 即  $\text{Var}(u_i) = \sigma^2$ ,  $\text{Cov}(u_i, u_j) = 0$ , 那么

$$\mathbb{E}(u_i^2 x_i x_i') = \sigma^2 \mathbb{E}(x_i x_i')$$

从而

$$\sqrt{N}(\hat{\beta} - \beta) \stackrel{a}{\sim} N(0, \sigma^2 [\mathbb{E}(x_i x_i')]^{-1})$$

注意到在以上渐进分布的方差估计中,  $\sigma^2$  仍然是未知的, 因而我们需要对  $\sigma^2$  进行估计。在小样本性质中, 我们使用

$$s^2 = \frac{\hat{e}'\hat{e}}{N - K}$$

对  $\sigma^2$  进行估计, 现在我们讨论  $s^2$  的大样本性质, 即是否有  $s^2 \xrightarrow{P} \sigma^2$ 。注意到

$$\hat{e}'\hat{e} = u' M u = u' u - u' X (X' X)^{-1} X' u$$

其中  $u' u = \sum_{i=1}^N u_i^2$ ,  $X' u = \sum_{i=1}^N u_i x_i$ ,  $X' X = \sum_{i=1}^N x_i x_i'$ , 因而:

$$s^2 = \frac{N}{N - K} \left[ \frac{\sum_{i=1}^N u_i^2}{N} - \frac{\sum_{i=1}^N u_i x_i'}{N} \left( \frac{\sum_{i=1}^N x_i x_i'}{N} \right)^{-1} \frac{\sum_{i=1}^N u_i x_i}{N} \right]$$

根据大数定律,  $\frac{1}{N} \sum_{i=1}^N u_i^2 \xrightarrow{P} \mathbb{E}(u_i^2) = \sigma^2$ ,  $\frac{1}{N} \sum_{i=1}^N u_i x_i \xrightarrow{P} \mathbb{E}(u_i x_i) = 0$ , 因而:

$$s^2 = \frac{N}{N - K} \frac{\sum_{i=1}^N u_i^2}{N} + o_p(1) \xrightarrow{P} \sigma^2$$

因而  $s^2$  是  $\sigma^2$  的一致估计, 进而可以得到  $\hat{\beta}$  的方差的估计量:

$$\widehat{\text{Var}}(\hat{\beta}) = s^2 (X' X)^{-1}$$

以上方差的估计量是基于同方差 (homoskedasticity) 的假定下得到的, 然而现实中同方差的假定仍然很强, **异方差 (heteroskedasticity)** 的存在, 即  $\text{Var}(u_i) = \sigma_i^2 \neq \sigma^2$  使得以上对于估计量方差的估计变的不再可靠。

需要注意的是，异方差的存在并不影响参数的一致性。一致性只要求外生性假设，即假设  $\mathbb{E}(u_i|x_i) = 0$ ，或者  $\mathbb{E}(x_i u_i) = 0$  即可，并不需要同方差假设。然而异方差的存在却会影响推断，即影响估计量的标准误的估计，从而影响假设检验。

由于  $\text{Var}(u_i) = \sigma_i^2 \neq \sigma^2$ ，因而  $\text{Var}(u) = \sigma^2 I$  不再成立，因而我们需要重新估计  $\mathbb{E}(u_i^2 x_i x_i')$ 。由于

$$\hat{u}_i = y_i - x_i' \hat{\beta} = y_i - x_i' \beta + x_i' \beta - x_i' \hat{\beta} = u_i + x_i (\beta - \hat{\beta}) = u_i + o_p(1)$$

因而我们可以使用

$$\begin{aligned} \frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i' &= \frac{1}{N} \sum_{i=1}^N (u_i + o_p(1))^2 x_i x_i' \\ &= \frac{1}{N} \sum_{i=1}^N u_i^2 x_i x_i' + o_p(1) \\ &\xrightarrow{P} \mathbb{E}(u_i^2 x_i x_i') \end{aligned}$$

因而在异方差存在的情况下，我们可以使用  $\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i'$  对  $\mathbb{E}(x_i u_i u_i' x_i')$  进行估计，因而  $\hat{\beta}$  的方差的估计量为：

$$\widehat{\text{Var}}(\hat{\beta}) = (X'X)^{-1} \left( \frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i' \right) (X'X)^{-1}$$

以上估计量称为怀特异方差稳健标准误 (White's heteroskedasticity robust standard error)。