

线性回归

司继春

上海对外经贸大学统计与信息学院

1 外生性

以上我们从拟合和几何的角度讨论了线性回归。而在计量经济学中，回归的目的在于解释而非预测，即关心所谓的因果效应（Causal effects）。比如，在计量经济学中，我们可能关心受教育程度对未来收入的影响，其目的不是为了使用受教育程度预测个人的收入，而是关心受教育程度是不是导致了个人可以获得更高的收入。为了得到因果效应，我们就必须在模型中做一些假设。

在上面的讨论中，我们通过最小化：

$$\hat{\beta} = \arg \min_b \sum_{i=1}^N e_i^2 = \arg \min_b e'e = \arg \min_b (y - Xb)'(y - Xb)$$

得到了多元线性回归。在这里，最小二乘法强调的是拟合。而如果我们希望得到所谓的因果效应，最关键的假设是所谓的外生性（Exogeneity）假设，即对于回归方程：

$$y_i = x_i' \beta + u_i$$

外生性假设即：

$$\mathbb{E}(u_i | x_i) = 0$$

即回归方程中的解释变量与误差项无关。

然而现实中很多应用都不满足这一假设。比如在以上受教育程度的例子中，尽管我们可以使用受教育程度预测个人的收入，但是如果简单使用线性回归解释个人的收入，现实数据可能并不满足以上的外生性假设。比如，个人的能力（ability）可能会影响个人能否上大学，同时也会影响其毕业之后的收入。即，能上大学的个人普遍来说能力更强，可能即使他不上大学，其收入也比较高。我们可以使用如下方程表示：

$$income_i = \gamma \cdot edu_i + x_i' \beta + ability_i + \epsilon_i$$

其中 x_i 为其他外生的控制变量。现实问题是，尽管能力对收入有影响，然而能

力是不可观测的，因而我们实际可以做的回归是：

$$income_i = \gamma \cdot edu_i + x_i' \beta + u_i$$

其中 $u_i = ability_i + \epsilon_i$ 。由于教育程度与能力相关，因而 $Cov(ability_i, edu_i) \neq 0$ ，从而 $Cov(u_i, edu_i) \neq 0$ ，因而 $E(u_i|x_i) \neq 0$ ，外生性假设无法满足。

当外生性假设无法满足时，我们需要一些其他的计量方法进行处理，比如下面将要介绍的工具变量法。现在，我们假设外生性假设成立，并在此基础上讨论参数的估计和推断问题。

2 外生性条件下的估计

对于回归方程：

$$y_i = x_i' \beta + u_i$$

其中 x_i 为 k 维向量，代表解释变量； β 为解释变量的系数； u_i 为误差项。如果外生性假设成立，即 $E(u_i|x_i) = 0$ ，那么根据条件期望的性质，必然有：

$$E(x_i u_i) = E[E(x_i u_i|x_i)] = E[x_i E(u_i|x_i)] = E[x_i \cdot 0] = 0$$

因而外生性假设保证了误差项 u_i 与 x_i 之间是不相关的。进而，我么可以使用矩估计的方法对 β 进行估计。注意到不可观测的 u_i 可以写为：

$$u_i = y_i - x_i' \beta$$

从而：

$$E[(y_i - x_i' \beta) x_i] = 0$$

注意由于 $u_i = y_i - x_i' \beta$ 为标量，而 x_i 为 $K \times 1$ 的向量，因而以上方程实际上包含着 K 个矩条件。对以上方程进行整理，得到：

$$E(x_i x_i') \beta = E(x_i y_i)$$

如果假设 $E(x_i x_i')$ 可逆，那么：

$$\beta = [E(x_i x_i')]^{-1} E(x_i y_i)$$

根据矩估计的思想，如果我们分别使用均值：

$$\frac{1}{N} \sum_{i=1}^N x_i x_i' \text{ 和 } \frac{1}{N} \sum_{i=1}^N x_i y_i$$

代替总体均值，那么就得到了以上问题的矩估计：

$$\hat{\beta} = \left[\frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i = \left[\sum_{i=1}^N x_i x_i' \right]^{-1} \sum_{i=1}^N x_i y_i$$

注意以上估计实际上就是最小二乘估计： $\hat{\beta} = (X'X)^{-1} X'Y$ 。

以上矩估计是在外生性假设的基础之上得到的。如果在外生性假设上更进一步，不仅假设 $\mathbb{E}(u_i|x_i) = 0$ ，同时假设 $u_i|x_i$ 的分布，比如正态分布，我们还可以得到 β 的极大似然估计。如果假设 $u_i|x_i \sim N(0, \sigma^2)$ ，那么 $y_i|x_i \sim N(x_i'\beta, \sigma^2)$ ，因而其条件极大似然函数为：

$$L(y|x) = \sum_{i=1}^N \left[-\ln(2\pi) - \ln \sigma - \frac{(y_i - x_i'\beta)^2}{\sigma^2} \right]$$

最大化以上似然函数，实际上等价于最小化 $\sum_{i=1}^N (y_i - x_i'\beta)^2$ ，即最小二乘的目标函数，因而在正态分布的假设下，使用条件极大似然方法得到的 β 的估计同样也是最小二乘估计量。

3 回归系数的解释

在以上的回归方程中，由于我们假设了 $\mathbb{E}(u_i|x_i) = 0$ ，那么 y_i 给定 x_i 的条件期望：

$$\mathbb{E}(y_i|x_i) = x_i'\beta$$

其中系数可以理解为条件期望 $\mathbb{E}(y_i|x_i)$ 对 x_i 的偏导，即：

$$\beta_k = \frac{\partial \mathbb{E}(y_i|x_i)}{\partial x_{ik}}$$

即系数 β_k 可以解释为变量 x_{ik} 对条件期望 $\mathbb{E}(y_i|x_i)$ 的偏效应 (partial effects)。使用平均偏效应有助于我们解释估计所得到的系数的含义，比如如下几种特殊情形：

1. 若 $y_i = \beta_1 \cdot x_{i1} + x_i'\beta + u_i$ ，那么偏效应：

$$\frac{\partial \mathbb{E}(y_i|x_{i1}, x_i)}{\partial x_{i1}} = \beta_1$$

即 x_{i1} 每增加一单位，则 y_i 平均增加 β_1 单位。

2. 若 $y_i = \beta_1 \cdot x_{i1} + \beta_2 x_{i1}^2 + x_i'\beta + u_i$ ，那么偏效应：

$$\frac{\partial \mathbb{E}(y_i|x_{i1}, x_i)}{\partial x_{i1}} = \beta_1 + 2\beta_2 x_{i1}$$

那么意味着 x_{i1} 对 y_i 的影响是非线性的, 如果 $\beta_2 > 0$, 那么 x_{i1} 对 y_i 的影响随着 x_{i1} 的增加而增加。

3. 若 $y_i = \beta_1 \cdot x_{i1} + \beta_2 x_{i1} x_{i2} + \beta_3 x_{i2} + x_i' \beta + u_i$, 那么偏效应:

$$\frac{\partial \mathbb{E}(y_i | x_{i1}, x_{i2}, x_i)}{\partial x_{i1}} = \beta_1 + \beta_2 x_{i2}$$

那么意味着 x_{i1} 对 y_i 的影响收到另外一个变量 x_{i2} 的影响, 如果 $\beta_2 > 0$, 那么 x_{i1} 对 y_i 的影响随着 x_{i2} 的增加而增加。

4. 若 $\ln y_i = \beta_1 \cdot \ln x_{i1} + x_i' \beta + u_i$, 那么偏效应:

$$\frac{\partial \mathbb{E}(\ln y_i | x_{i1}, x_i)}{\partial \ln x_{i1}} = \beta_1$$

注意由于 $\partial \ln y_i = \frac{1}{y_i} \partial y_i$, 同理 $\partial \ln x_{i1} = \frac{1}{x_{i1}} \partial x_{i1}$, 即百分比变动, 因而 β_1 可以解释为当 x_{i1} 增加 1% 时, y_i 增加的百分比变动的期望, 即弹性。注意由于

$$\mathbb{E}(\ln y_i | x_{i1}, x_i) \neq \ln \mathbb{E}(y_i | x_{i1}, x_i)$$

因而 β_1 不能被解释为当 x_{i1} 增加 1% 时条件期望变动的百分比。

注意以上 3、4 两个例子中, 得到的偏效应都是一个变量的函数, 即 x_{i1} 对 y_i 的影响不是一个常数。在这种情况下, 我们经常会关心所谓的平均偏效应 (Average partial effects), 即 x_{i1} 对 y_i 的影响的均值:

$$\mathbb{E} \left(\frac{\partial \mathbb{E}(y_i | x_i)}{\partial x_{ij}} \right)$$

例如在 3 中, 平均偏效应为:

$$\mathbb{E} \left[\frac{\partial \mathbb{E}(y_i | x_{i1}, x_{i2}, x_i)}{\partial x_{i1}} \right] = \beta_1 + \beta_2 \mathbb{E}(x_{i2})$$

在实践中, 对于有交叉项、平方项存在的回归中, 我们经常会对变量去平均。例如在 3 的回归方程中:

$$y_i = \beta_1 \cdot x_{i1} + \beta_2 x_{i1} x_{i2} + \beta_3 x_{i2} + x_i' \beta + u_i$$

令 $x_{i1}^* = x_{i1} - \bar{x}_1$, 同时令 $x_{i2}^* = x_{i2} - \bar{x}_2$, 我们经常使用回归:

$$y_i = \beta_1 \cdot x_{i1}^* + \beta_2 x_{i1}^* x_{i2}^* + \beta_3 x_{i2}^* + x_i' \beta + u_i$$

如此，我们可以得到平均偏效应为：

$$\mathbb{E} \left[\frac{\partial \mathbb{E}(y_i | x_{i1}^*, x_{i2}^*, x_i)}{\partial x_{i1}^*} \right] = \beta_1 + \beta_2 \mathbb{E}(x_{i2}^*) = \beta_1$$

即去平均处理后，得到的回归系数即为平均偏效应。

最后一个例子，在学习极大似然估计时我们学习了二元选择模型，即如果 $y_i = 0/1$ 时，我们通过设定 $y_i = 1$ 的条件概率：

$$P(y_i | x_i) = \mathbb{E}(y_i | x_i) = F(x_i' \beta)$$

对以上模型进行了估计，其中 F 一般取为标准正态分布或者标准 Logistic 分布的分布函数。实际上，在 Logit 或者 Probit 模型中估计出来的 β 是没有经济学含义的，为了使得 β 有意义，我们同样需要对条件期望求偏导，得到偏效应：

$$\frac{\partial \mathbb{E}(y_i | x_i)}{\partial x_{ik}} = \frac{\partial P(y_i | x_i)}{\partial x_{ik}} = f(x_i' \beta) \beta_k$$

上式可以解释为，当 x_{ik} 增加一单位时， $y_i = 1$ 的概率增加了 $f(x_i' \beta) \beta_k$ 。注意以上概率增加的偏效应是随着 x_i 的变化而变化的，因而我们也需要计算平均偏效应：

$$\mathbb{E} \left[\frac{\partial \mathbb{E}(y_i | x_i)}{\partial x_{ik}} \right] = \beta_k \mathbb{E}[f(x_i' \beta)]$$

上式涉及到了一个非线性的密度函数 $f(\cdot)$ 的期望，通常来说比较难以求出，因而给定 β 的估计 $\hat{\beta}$ ，我们可以使用：

$$\widehat{APE} = \hat{\beta}_k \overline{f(x_i' \hat{\beta})}$$

对平均偏效应进行估计。或者，可以简单的计算在 x_i 的平均处的偏效应： $\hat{\beta}_k f(\bar{x}' \hat{\beta})$ 。注意由于密度函数通常为非线性函数，因而以上两种估计通常并不相等。在 Stata 中，可以使用 margins 命令估计偏效应。

4 线性回归的小样本统计性质

在这里我们将讨论线性回归的小样本统计性质，包括无偏性即参数估计 $\hat{\beta}$ 的小样本分布。

首先对于无偏性，由于：

$$\begin{aligned} \hat{\beta} &= (X'X)^{-1} X'Y \\ &= (X'X)^{-1} X'(X\beta + u) \\ &= \beta + (X'X)^{-1} X'u \end{aligned}$$

其中

$$u = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_N \end{bmatrix}$$

为误差项向量。从而：

$$\begin{aligned} \mathbb{E}(\hat{\beta}) &= \beta + \mathbb{E}\left((X'X)^{-1} X'u\right) \\ &= \beta + \mathbb{E}\left[\mathbb{E}\left((X'X)^{-1} X'u|X\right)\right] \\ &= \beta + \mathbb{E}\left[(X'X)^{-1} X'\mathbb{E}(u|X)\right] \\ &= \beta \end{aligned}$$

因而在外生性假设下，最小二乘估计是真实参数 β 的无偏估计。

此外我们还可以计算最小二乘估计 $\hat{\beta}$ 的方差。注意到由于 $\hat{\beta} - \beta = (X'X)^{-1} X'u$ ，因而 $\hat{\beta}$ 的条件协方差矩阵为：

$$\begin{aligned} \text{Var}(\hat{\beta}|X) &= \mathbb{E}\left[(\hat{\beta} - \beta)(\hat{\beta} - \beta)'|X\right] \\ &= \mathbb{E}\left[(X'X)^{-1} X'uu'X(X'X)^{-1}|X\right] \\ &= (X'X)^{-1} X'\mathbb{E}[uu'|X]X(X'X)^{-1} \end{aligned}$$

在同方差 (homoscedasticity) 假定下，即假定 $\text{Var}(u_i|x_i) = \sigma^2$ ，以及假定不存在自相关，即 $\text{Cov}(u_i, u_j) = 0$ 的条件下，那么

$$\mathbb{E}(uu'|X) = \sigma^2 I = \begin{bmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{bmatrix}_{N \times N}$$

则上式可以化简为：

$$\begin{aligned} \text{Var}(\hat{\beta}|X) &= (X'X)^{-1} X'\mathbb{E}[uu'|X]X(X'X)^{-1} \\ &= (X'X)^{-1} X'\sigma^2 IX(X'X)^{-1} \\ &= \sigma^2 (X'X)^{-1} \end{aligned}$$

实际上我们可以证明，在 β 的所有线性无偏估计量中，最小二乘估计量是方差最小的估计量。其中「线性性」意味着 β 的估计值是 y 的一个线性函数，即可以写成 $\tilde{\beta} = Cy$ 的形式， C 是一个不依赖于 y 的矩阵。

现在不妨假设存在另外一个 β 的线性无偏估计量 $\tilde{\beta} = Cy$, 由于无偏性, 有:

$$\beta = \mathbb{E}(\tilde{\beta}) = \mathbb{E}(Cy) = \mathbb{E}[C(X\beta + u)] = \mathbb{E}(CX)\beta + \mathbb{E}(Cu)$$

上式这意味着 $CX = I$ 以及 $\mathbb{E}(Cu) = 0$ 。注意 $\tilde{\beta}$ 的方差为:

$$\text{Var}(\tilde{\beta}|X) = \sigma^2 CC'$$

因而其两个估计量方差之逆的差为:

$$\begin{aligned} \text{Var}(\hat{\beta}|X)^{-1} - \text{Var}(\tilde{\beta}|X)^{-1} &= \frac{1}{\sigma^2} [X'X - (CC')^{-1}] \\ &= \frac{1}{\sigma^2} [X'X - X'C'(CC')^{-1}CX] \\ &= \frac{1}{\sigma^2} X' [I - C'(CC')^{-1}C] X \end{aligned}$$

注意到由于矩阵 $I - C'(CC')^{-1}C$ 为幂等矩阵, 因而一定是半正定矩阵, 从而:

$$\text{Var}(\hat{\beta}|X)^{-1} - \text{Var}(\tilde{\beta}|X)^{-1} \geq 0$$

从而 $\text{Var}(\hat{\beta}|X) \leq \text{Var}(\tilde{\beta}|X)$ 。最后, 获得了条件方差之后, 我们可以计算 $\hat{\beta}$ 的无条件方差, 即:

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \mathbb{E}(\text{Var}(\hat{\beta}|X)) + \text{Var}(\mathbb{E}(\hat{\beta}|X)) \\ &= \sigma^2 \mathbb{E}[(X'X)^{-1}] + \text{Var}(\beta) \\ &= \sigma^2 \mathbb{E}[(X'X)^{-1}] \end{aligned}$$

同理 $\text{Var}(\tilde{\beta}) = \sigma^2 CC'$, 因而最小二乘估计量 $\hat{\beta}$ 的方差 (条件方差及无条件方差) 在所有线性无偏估计量中是最小的。正是由于以上性质, 我们称最小二乘估计量 $\hat{\beta}$ 为**最优线性无偏估计量** (Best linear unbiased estimator, BLUE)。

此外, 由于 σ^2 未知, 因而在推断中我们需要对 σ^2 进行估计。记残差:

$$\hat{e} = Y - X\hat{\beta} = MY = M(X'\beta + u) = Mu$$

从而残差平方和为:

$$\hat{e}'\hat{e} = u'Mu$$

其期望：

$$\begin{aligned}
 \mathbb{E}(\hat{e}'\hat{e}) &= \mathbb{E}(u'Mu) \\
 &= \mathbb{E}[\text{tr}(u'Mu)] \\
 &= \mathbb{E}[\text{tr}(Mu u')] \\
 &= \text{tr}[\mathbb{E}(Mu u')] \\
 &= \text{tr}[\mathbb{E}(\mathbb{E}(Mu u'|X))] \\
 &= \text{tr}[\mathbb{E}(M\mathbb{E}(u u'|X))] \\
 &= \text{tr}[\mathbb{E}(\sigma^2 M)] \\
 &= \sigma^2 \mathbb{E}\left(\text{tr}\left(I - X(X'X)^{-1}X'\right)\right) \\
 &= \sigma^2 \mathbb{E}\left(\text{tr}(I) - \text{tr}\left(X(X'X)^{-1}X'\right)\right) \\
 &= \sigma^2 \left(N - \text{tr}\left((X'X)^{-1}X'X\right)\right) \\
 &= \sigma^2 (N - K)
 \end{aligned}$$

因而：

$$\sigma^2 = \frac{\mathbb{E}(\hat{e}'\hat{e})}{N - K}$$

从而我们可以使用残差平方和对 σ^2 进行估计，即使用：

$$s^2 = \frac{\hat{e}'\hat{e}}{N - K}$$

对 σ^2 进行估计，根据以上可知 s^2 是 σ^2 的无偏估计。

以上我们得到了最小二乘估计量的最优无偏线性估计量的性质，进而讨论了误差项方差的估计，然而对于统计推断来说，我们还需要估计量的抽样分布。然而在对误差项 u 不做任何假定的情况下，小样本条件下我们不能得到估计量的精确分布，因而必须对 u 的分布做进一步的假设。一个常用的假设是正态性假设，即假设误差项 u_i 为独立同分布的正态分布， $u_i \sim N(0, \sigma^2)$ ，或者 $u \sim N(0, \sigma^2 I)$ 。

在正态性假设基础之上，由于 $\hat{\beta} - \beta = (X'X)^{-1}X'u$ ，因而：

$$\hat{\beta}|X \sim N\left(\beta, \sigma^2 (X'X)^{-1}\right)$$

即最小二乘估计量 $\hat{\beta}$ 服从联合正态分布。进而，单独某一个系数的分布也是正态分布，即：

$$\hat{\beta}_k|X \sim N\left(\beta, \sigma^2 (X'X)^{-1}_{kk}\right)$$

其中 $(X'X)_{kk}^{-1}$ 代表矩阵 $(X'X)^{-1}$ 的第 k 行第 k 列的元素值。现在，令

$$t_k = \frac{\hat{\beta}_k - b}{\sqrt{s^2 (X'X)_{kk}^{-1}}}$$

可以得到给定 X 的条件下, $t_k|X \sim t(N-K)$ 。注意以上的 t 分布不依赖于 X , 即 t_k 的分布不依赖于 X , 因而 t_k 的无条件分布也是服从 $t(N-K)$ 分布的, 所以对于原假设:

$$H_0: \beta_j = b$$

我们可以使用统计量

$$t_j = \frac{\hat{\beta}_j - b}{\sqrt{s^2 (X'X)_{jj}^{-1}}} \sim t(N-K)$$

对单个系数进行假设检验。

进一步, 很多时候我们希望针对一个或者多个系数之间的线性关系做检验, 比如我们的原假设可能为:

$$H_0: \beta_2 + \beta_3 = 1, \beta_1 = 0$$

我们通常会使用矩阵的方式表达上述原假设, 即:

$$H_0: R\beta + q = 0$$

其中 R 为 $r \times K$ 维的矩阵, q 为 $r \times 1$ 维向量, r 就是我们要检验的线性关系的个数。比如在上例中, 我们需要检验 $\beta_2 + \beta_3 = 1$, 同时 $\beta_1 = 0$, 参数个数 $K = 4$, 那么可以取

$$R = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 \end{bmatrix}, q = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

从而原假设可以写为:

$$R\beta + q = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{bmatrix} + \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} \beta_1 \\ \beta_2 + \beta_3 - 1 \end{bmatrix} = 0$$

在这种情况下, 我们可以使用 Wald 检验。注意到, 由于

$$\hat{\beta}|X \sim N(\beta, \sigma^2 (X'X)^{-1})$$

因而

$$R\hat{\beta} + q|X \sim N\left(R\beta + q, \sigma^2 R(X'X)^{-1}R'\right)$$

从而在原假设 $R\beta + q = 0$ 的条件下:

$$R\hat{\beta} + q|X \sim N\left(0, \sigma^2 R(X'X)^{-1}R'\right)$$

两边同时乘以 $\left[\sigma^2 R(X'X)^{-1}R'\right]^{-1/2}$ 得到:

$$\left[\sigma^2 R(X'X)^{-1}R'\right]^{-1/2} (R\hat{\beta} + q) \sim N(0, I_{r \times r})$$

注意由于 R 为 $r \times K$ 维, 因而以上方程是一个 $r \times 1$ 的向量。将其与其转置相乘, 就得到了

$$(R\hat{\beta} + q)' \left[\sigma^2 R(X'X)^{-1}R'\right]^{-1} (R\hat{\beta} + q) \sim \chi^2(r)$$

然而注意到由于 σ^2 是未知的, 因而需要使用 s^2 进行替代。下面我们将会看到, $s^2 = \sigma^2 + o_p(1)$, 因而如此替代并不会改变以上统计量的大样本分布, 即仍然可以使用

$$(R\hat{\beta} + q)' \left[s^2 R(X'X)^{-1}R'\right]^{-1} (R\hat{\beta} + q) \stackrel{a}{\sim} \chi^2(r)$$

进行假设检验。

5 联合检验与方差分析

如果我们希望检验是否所有的 β_j 都等于 0 (除常数项), 那么可以使用 F 检验。不失一般性, 假设截距项为 β_1 , 那么原假设:

$$H_0: \beta_2 = \beta_3 = \dots = \beta_k = 0$$

可以使用统计量:

$$F = \frac{R^2/(K-1)}{(1-R^2)/(N-K)} \sim F(k-1, N-K)$$

在原假设条件下, $R^2 = 0$, 因而只需要检验 $F = 0$ 即可。实际上, 由于:

$$R^2 = \frac{\hat{y}'M_0\hat{y}}{y'M_0y} = 1 - \frac{\hat{e}'\hat{e}}{y'M_0y}$$

因而

$$F = \frac{\hat{y}'M_0\hat{y}/(K-1)}{\hat{e}'\hat{e}/(N-K)}$$

其中：

$$M_0 \hat{y} = M_0 P y = M_0 (X\beta + Pu)$$

在原假设条件下， $X\beta = \beta_1 \iota$ ，而 $M_0 \iota = (I - \frac{1}{N} \iota \iota') \iota = \iota - \iota = 0$ ，因而在原假设条件下， $M_0 \hat{y} = M_0 P u$ 。而由于：

$$M_0 P = \left(I - \frac{1}{N} \iota \iota' \right) P = P - \frac{1}{N} \iota \iota'$$

为实对称幂等矩阵，且 $\text{tr}(M_0 P) = \text{tr}(P) - \text{tr}(\frac{1}{N} \iota \iota') = K - 1$ ，如果 $u \sim N(0, \sigma^2 I)$ ，那么：

$$\frac{1}{\sigma} \hat{y}' M_0 \hat{y} = \frac{1}{\sigma} u' M_0 P u \sim \chi^2(K - 1)$$

同理 $\hat{e} = M u$ ， $\text{tr}(M) = \text{tr}(I - P) = N - K$ ，因而：

$$\frac{1}{\sigma} \hat{e}' \hat{e} = \frac{1}{\sigma} u' M u \sim \chi^2(N - K)$$

最后，注意到 $M_0 P \cdot M = M_0 (P M) = 0$ ，因而 $\frac{1}{\sigma} \hat{y}' M_0 \hat{y}$ 与 $\frac{1}{\sigma} \hat{e}' \hat{e}$ 为独立的 χ^2 分布，从而

$$F = \frac{\hat{y}' M_0 \hat{y} / (K - 1)}{\hat{e}' \hat{e} / (N - K)} \sim F(K - 1, N - K)$$

6 线性回归的大样本统计性质

下面我们来讨论最小二乘估计量的大样本性质。首先我们讨论最小二乘估计量的一致性。注意到最小二乘估计量为：

$$\hat{\beta} = \left[\frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i$$

式中出现了两个平均，我们可以分别对以上两部分使用大数定律。在一定比较宽松的假定下，根据大数定律，有：

$$\frac{1}{N} \sum_{i=1}^N x_i x_i' \xrightarrow{p} \mathbb{E}(x_i x_i')$$

以及：

$$\frac{1}{N} \sum_{i=1}^N x_i y_i \xrightarrow{p} \mathbb{E}(x_i y_i) = \mathbb{E}(x_i (x_i' \beta + u)) = \mathbb{E}(x_i x_i') \beta$$

由于矩阵的逆也是连续函数，因而如果 $[\mathbb{E}(x_i x_i')]^{-1}$ 存在，那么：

$$\hat{\beta} = \left[\frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i \xrightarrow{p} [\mathbb{E}(x_i x_i')]^{-1} \mathbb{E}(x_i x_i') \beta = \beta$$

因而一致性成立。

此外，我们还可以建立 $\hat{\beta}$ 的渐进正态性。注意到由于

$$\hat{\beta} = \left[\frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i = \beta + \left[\frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{N} \sum_{i=1}^N x_i u_i$$

根据大数定律，我们关注 $\sqrt{N}(\hat{\beta} - \beta)$ 的渐进分布。由于：

$$\sqrt{N}(\hat{\beta} - \beta) = \left[\frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{\sqrt{N}} \sum_{i=1}^N x_i u_i$$

其中第一部分可以根据大数定律，得到 $\left[\frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \xrightarrow{p} [\mathbb{E}(x_i x_i')]^{-1}$ ，而第二部分可以使用中心极限定理：

$$\frac{1}{\sqrt{N}} \sum_{i=1}^N x_i u_i \stackrel{a}{\sim} N(\mathbb{E}(x_i u_i), \text{Var}(x_i u_i))$$

由于 $\mathbb{E}(x_i u_i) = 0$ ，因而协方差矩阵：

$$\text{Var}(x_i u_i) = \mathbb{E}[(x_i u_i)(x_i u_i)'] = \mathbb{E}(u_i^2 x_i x_i')$$

因而：

$$\frac{1}{\sqrt{N}} \sum_{i=1}^N x_i u_i \stackrel{a}{\sim} N(0, \mathbb{E}(u_i^2 x_i x_i'))$$

综上，我们可以得到：

$$\begin{aligned} \sqrt{N}(\hat{\beta} - \beta) &= \left[\frac{1}{N} \sum_{i=1}^N x_i x_i' \right]^{-1} \frac{1}{\sqrt{N}} \sum_{i=1}^N x_i u_i \\ &= [\mathbb{E}(x_i x_i')]^{-1} \frac{1}{\sqrt{N}} \sum_{i=1}^N x_i u_i + o_p(1) \\ &\stackrel{a}{\sim} N\left(0, [\mathbb{E}(x_i x_i')]^{-1} \mathbb{E}(u_i^2 x_i x_i') [\mathbb{E}(x_i x_i')]^{-1}\right) \end{aligned}$$

如果我们假设 u_i 是同方差的，以上渐进方差还可以继续化简。即假设 $\text{Var}(u_i|x_i) =$

$\sigma^2, \text{Cov}(u_i, u_j) = 0$, 那么

$$\mathbb{E}(u_i^2 x_i x_i') = \mathbb{E}[\mathbb{E}(u_i^2 x_i x_i' | x_i)] = \mathbb{E}[x_i x_i' \mathbb{E}(u_i^2 | x_i)] = \sigma^2 \mathbb{E}(x_i x_i')$$

从而

$$\sqrt{N}(\hat{\beta} - \beta) \stackrel{a}{\sim} N(0, \sigma^2 [\mathbb{E}(x_i x_i')]^{-1})$$

注意到在以上渐进分布的方差估计中, σ^2 仍然是未知的, 因而我们需要对 σ^2 进行估计。在小样本性质中, 我们使用

$$s^2 = \frac{\hat{e}'\hat{e}}{N - K}$$

对 σ^2 进行估计, 现在我们讨论 s^2 的大样本性质, 即是否有 $s^2 \xrightarrow{P} \sigma^2$ 。注意到

$$\hat{e}'\hat{e} = u'Mu = u'u - u'X(X'X)^{-1}X'u$$

其中 $u'u = \sum_{i=1}^N u_i^2$, $X'u = \sum_{i=1}^N u_i x_i$, $X'X = \sum_{i=1}^N x_i x_i'$, 因而:

$$s^2 = \frac{N}{N - K} \left[\frac{\sum_{i=1}^N u_i^2}{N} - \frac{\sum_{i=1}^N u_i x_i'}{N} \left(\frac{\sum_{i=1}^N x_i x_i'}{N} \right)^{-1} \frac{\sum_{i=1}^N u_i x_i}{N} \right]$$

根据大数定律, $\frac{1}{N} \sum_{i=1}^N u_i^2 \xrightarrow{P} \mathbb{E}(u_i^2) = \sigma^2$, $\frac{1}{N} \sum_{i=1}^N u_i x_i \xrightarrow{P} \mathbb{E}(u_i x_i) = 0$, 因而:

$$s^2 = \frac{N}{N - K} \frac{\sum_{i=1}^N u_i^2}{N} + o_p(1) \xrightarrow{P} \sigma^2$$

因而 s^2 是 σ^2 的一致估计, 进而可以得到 $\hat{\beta}$ 的方差的估计量:

$$\widehat{\text{Var}}(\hat{\beta}) = s^2 (X'X)^{-1}$$

以上方差的估计量是基于同方差 (homoscedasticity) 的假定下得到的, 然而现实中同方差的假定仍然很强, **异方差 (heteroscedasticity)** 的存在, 即 $\text{Var}(u_i | x_i) = \sigma_i^2 \neq \sigma^2$ 使得以上对于估计量方差的估计变的不再可靠。

需要注意的是, 异方差的存在并不影响参数的一致性。一致性只要求外生性假设, 即假设 $\mathbb{E}(u_i | x_i) = 0$, 或者 $\mathbb{E}(x_i u_i) = 0$ 即可, 并不需要同方差假设。然而异方差的存在却会影响推断, 即影响估计量的标准误的估计, 从而影响假设检验。

由于 $\text{Var}(u_i | x_i) = \sigma_i^2 \neq \sigma^2$, 因而 $\mathbb{E}(u_i^2 x_i x_i') = \sigma^2 \mathbb{E}(x_i x_i')$ 不再成立, 我们需要重新估计 $\mathbb{E}(u_i^2 x_i x_i')$ 。由于

$$\hat{u}_i = y_i - x_i' \hat{\beta} = y_i - x_i' \beta + x_i' \beta - x_i' \hat{\beta} = u_i + x_i (\beta - \hat{\beta}) = u_i + o_p(1)$$

因而我们可以使用

$$\begin{aligned}\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i' &= \frac{1}{N} \sum_{i=1}^N (u_i + o_p(1))^2 x_i x_i' \\ &= \frac{1}{N} \sum_{i=1}^N u_i^2 x_i x_i' + \frac{1}{N} \sum_{i=1}^N o_p(1) \\ &\xrightarrow{P} \mathbb{E}(u_i^2 x_i x_i')\end{aligned}$$

因而在异方差存在的情况下，我们可以使用 $\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i'$ 对 $\mathbb{E}(u_i^2 x_i x_i')$ 进行估计，因而 $\hat{\beta}$ 的方差的估计量为：

$$\widehat{\text{Var}}(\hat{\beta}) = (X'X)^{-1} \left(\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i' \right) (X'X)^{-1}$$

以上估计量称为怀特异方差稳健标准误 (White's heteroskedasticity robust standard error)。

如果异方差存在，但是我们没有使用异方差稳健的标准误，就会导致假设检验失效。比如在下面的例子中，我们人为设定了一个异方差，在此基础上进行了 1000 次模拟：

代码 1: 异方差的模拟

```
1 // file: white_hetero.do
2 cap program drop dgp
3 program define dgp, rclass
4     syntax [, obs(integer 100) robust b(real 0)]
5     drop _all
6     set obs `obs'
7     tempvar x y sigma
8     gen `x'=rnormal()
9     gen `sigma'=sqrt(`x'^2)
10    gen `y'=`b'*`x'+`sigma'*rnormal()
11    quietly: reg `y' `x', `robust'
12    return scalar b=_b[`x']
13    return scalar se=_se[`x']
14    if abs(_b[`x']/_se[`x'])>=1.96 {
15        return scalar rejected=1
16    }
17    else {
18        return scalar rejected=0
19    }
```

```

20 end
21
22 simulate rejected=r(rejected) b=r(b) se=r(se)/
23          */ ,reps(1000):dgp
24 su
25 simulate rejected=r(rejected) b=r(b) se=r(se)/
26          */ ,reps(1000):dgp, robust
27 su

```

在以上程序中，我们首先定义了一个程序 (program)，该程序会产生 ‘obs’ 个随机观测，其中 $x_i \sim N(0, 1)$ ，而误差项 $u_i | x_i \sim N(0, x_i^2)$ ，因而存在着异方差。接下来我们设定 $y_i = b \times x_i + u_i$ ，并使用最小二乘估计参数 b 。注意在该程序中有一个 ‘robust’ 选项，当使用该程序时，如果使用该选项，[‘robust’=’robust’]，因而在最小二乘估计时也会加入 robust 选项，即使用怀特异方差稳健标准误；如果不加该选项，则默认不适用怀特异方差稳健标准误。最后我们返回了 b 的估计值、 b 的标准误以及是否拒绝了 $H_0 : b = 0$ 的原假设。最后通过 simulate 前缀，重复该命令 1000 次，并记录下每一次 b 的估计值、 b 的标准误以及是否拒绝了原假设。由于：

$$\frac{\hat{b}}{s.e.(\hat{b})} \overset{a}{\sim} N(0, 1)$$

因而如果 $b = 0$ ，拒绝原假设（即 $\hat{b}/s.e.(\hat{b}) \geq 1.96$ ）的概率只有 5%，如果超过或者不足 5%，说明我们的假设检验出现了问题。

我们设 $b = 0$ 运行了以上程序，经过 1000 次模拟之后，我们发现：

1. \hat{b} 的均值大约为 0.007，与 0 相差无几，说明对 \hat{b} 的估计并没有出现太大的偏差；
2. 1000 次 \hat{b} 估计的标准差为 0.175 左右；
3. 如果不使用怀特异方差稳健的标准误，估计的 $s.e.(\hat{b})$ 平均为 0.099，严重低估了 \hat{b} 估计的标准误；
4. 相应的，如果不使用怀特异方差稳健的标准误，大约有 25% 次拒绝了原假设，远远大于 5%，意味着假设检验出现了问题；
5. 如果使用怀特异方差稳健的标准误，估计的 $s.e.(\hat{b})$ 平均为 0.16，与 \hat{b} 估计的标准差相差无几；
6. 相应的，使用怀特异方差稳健的标准误的条件下，大约有 6% 拒绝了原假设，约等于 5%，意味着假设检验问题不大。

以上模拟说明，当异方差存在时，尽管不会影响估计的一致性，但是异方差会影响 $s.e.(\hat{b})$ 的估计，从而对假设检验造成影响。

7 整群抽样

习题

练习 1. 请证明一元线性回归的无偏性和一致性。

练习 2. 请给出一个使用异方差标准误使得标准误变小的例子，并使用模拟的方法验证。