

## 第三节 · 线性代数

司继春

上海对外经贸大学统计与信息学院

### 1 向量与矩阵

对于两个集合  $A, B$ , 我们记  $A \times B = \{(a, b), \forall a \in A, b \in B\}$ , 即  $\times$  运算定义了一个二元组的集合, 我们称  $\times$  为**笛卡尔乘积** (**Cartesian product**)。比如, 如果我们选取  $A = \{\heartsuit, \spadesuit, \clubsuit, \diamondsuit\}, B = \{2, \dots, 10, J, Q, K, A\}$ , 那么我们就得到了一副扑克牌共 52 张牌的集合。而如果选取  $A = \mathbb{R}, B = \mathbb{R}$ , 那么  $\mathbb{R}^2 = \mathbb{R} \times \mathbb{R}$  为二维平面。

更一般的, 我们可以记

$$\begin{aligned}\Omega_1 \times \Omega_2 \times \cdots \times \Omega_d &= \times_{i=1}^n \Omega_i \\ &= \{(\omega_1, \omega_2, \dots, \omega_n), \omega_i \in \Omega_i, i = 1, \dots, n\}\end{aligned}$$

特别的,  $\mathbb{R}^n = \mathbb{R} \times \mathbb{R} \times \cdots \times \mathbb{R}$  为  $n$  维的**欧几里得空间** (**Euclidean space**), 其中  $\omega = (\omega_1, \dots, \omega_n) \in \mathbb{R}^n$  为**向量** (**vectors**)。向量可以按照行或者列排列, 分别称为行向量 (column vector) 或者列向量 (column vector), 不失一般性, 我们下面提到的向量都默认为列向量。行向量和列向量之间可以通过转置 (transpose) 得到, 即对于一个列向量  $\omega$ , 其转置记为  $\omega'$ , 为行向量。特别的, 我们记  $0$  为所有元素都等于 0 的向量, 即零向量, 而记  $\iota = [1, 1, \dots, 1]'$  为所有元素都为 1 的列向量:

$$0 = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \iota = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

令  $\alpha \in \mathbb{R}$  为标量,  $\omega, \eta \in \mathbb{R}^n$  为  $n$  维向量, 我们定义向量加法运算的数乘运算:

$$\omega + \eta = \begin{bmatrix} \omega_1 \\ \omega_2 \\ \vdots \\ \omega_n \end{bmatrix} + \begin{bmatrix} \eta_1 \\ \eta_2 \\ \vdots \\ \eta_n \end{bmatrix} = \begin{bmatrix} \omega_1 + \eta_1 \\ \omega_2 + \eta_2 \\ \vdots \\ \omega_n + \eta_n \end{bmatrix}, \alpha\omega = \begin{bmatrix} \alpha\omega_1 \\ \alpha\omega_2 \\ \vdots \\ \alpha\omega_n \end{bmatrix}$$

即对向量的每个元素相加，或者都乘以这个标量。

如果  $x \in \mathbb{R}^n, y \in \mathbb{R}^n$  我们可以定义**内积** (**inner product**) 或者**点乘积** (**dot product**) 为:

$$\langle x, y \rangle = x \cdot y = \sum_{i=1}^n x_i y_i$$

如果  $\langle x, y \rangle = 0$ , 我们称两个向量**正交** (**orthogonal**)。在几何上, 正交意味着两个向量是垂直的。

有了内积之后, 可以使用内积定义长度的概念, 即所谓的 (欧几里得) **范数** (**norm**):

$$\|x\| = \sqrt{\langle x, x \rangle} = \sqrt{\sum_{i=1}^n x_i^2}$$

以及两个向量间的**距离** (**metric**):

$$d(x, y) = \|x - y\| = \sqrt{\langle x - y, x - y \rangle} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

对于一个  $n$  维的欧几里得空间  $\mathbb{R}^n$ , 我们可以在这个空间上定义 Borel 域:

$$\mathcal{B}^n = \times_{i=1}^n \mathcal{B}_i = \sigma(\{\times_{i=1}^n A_i, A_i \in \mathcal{B}_i\})$$

如果我们把  $k$  个  $n$  维向量按列摆放在一起, 我们得到了一个  $n \times k$  维的**矩阵** (**matrix**)  $A_{n \times k} = [a_1, \dots, a_k]$ , 其中  $a_i$  为  $n$  维向量。我们也可以把向量看成是一个  $n \times 1$  维的矩阵。特别的, 如果  $k = n$ , 即一个行数与列数相等的矩阵, 我们称之为**方阵** (**square matrix**)。

对于矩阵, 我们同样可以类似定义加法和数乘运算:

$$A + B = \begin{bmatrix} a_1 & \cdots & a_k \end{bmatrix} + \begin{bmatrix} b_1 & \cdots & b_k \end{bmatrix} = \begin{bmatrix} a_1 + b_1 & \cdots & a_k + b_k \end{bmatrix}$$

$$\alpha A = \begin{bmatrix} \alpha a_1 & \cdots & \alpha a_k \end{bmatrix}$$

其中  $a_i, b_i$  为  $n \times 1$  维的列向量。自然的, 我们也可以定义矩阵的转置:

$$A' = \begin{bmatrix} a'_1 \\ \vdots \\ a'_k \end{bmatrix}$$

如果  $A$  为  $n \times k$  的矩阵, 那么其转置  $A'$  为  $k \times n$  的矩阵。矩阵的数乘、加法、转置等满足一些良好的性质, 比如:

- $(A + B) + C = A + (B + C)$
- $(\alpha + \beta) A = \alpha A + \beta A$

- $\alpha(A+B) = \alpha A + \alpha B$
- $\alpha(\beta A) = (\alpha\beta)A$
- $(A')' = A$
- $(A+B)' = A' + B'$

矩阵与向量之间的乘法运算可以定义为矩阵列向量的**线性组合** (linear combination), 即对于矩阵  $A_{n \times k} = [a_1, \dots, a_k]$  以及  $k$  维向量  $x = [x_1, \dots, x_k]'$ , 可以定义矩阵与向量的乘法为:

$$Ax = x_1 a_1 + \dots + x_k a_k = \sum_{j=1}^k x_j a_j$$

即  $a_j$  的一个线性组合。注意以上乘法的定义要求矩阵  $A$  的列数必须与向量  $x$  的维数一致。

如果存在一个非零向量  $x$ , 使得  $Ax = 0$ , 那么我们称向量  $a_1, \dots, a_k$  是**线性相依**的 (linearly dependent)。线性相依意味着其中的某个向量一定可以被其他向量线性表示出。比如, 不妨假设  $Ax^* = 0$ , 且  $x_1^* \neq 0$ , 那么必然有:

$$a_1 = -\frac{x_2^*}{x_1^*} a_2 - \dots - \frac{x_k^*}{x_1^*} a_k$$

即  $a_1$  可以通过其他几个向量线性表示出。而如果只有当  $x = 0$  时, 才有  $Ax = 0$ , 那么我们称向量  $a_1, \dots, a_k$  是**线性无关**或者**线性独立**的 (linearly independent)。比如矩阵:

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

其任何一个列向量都不可以被其他两个列向量线性表示出。

使用矩阵与向量的乘法我们可以定义两个矩阵之间的乘法, 对于矩阵  $A_{n \times k} = [a_1, \dots, a_k]$  以及  $B_{k \times m} = [b_1, \dots, b_m]$ , 其乘法定义为:

$$AB = A[b_1, \dots, b_m] = [Ab_1, \dots, Ab_m]_{n \times m}$$

即一个  $n \times k$  的矩阵与一个  $k \times m$  的矩阵相乘, 得到了一个  $n \times m$  的矩阵。对于矩阵相乘而言, 即使乘积都存在, 交换律也并不成立, 即  $AB \neq BA$ , 而其转置满足:  $(AB)' = B'A'$ 。

对于一个矩阵  $A_{n \times k} = [a_1, \dots, a_k]$ , 其列向量的所有子集即可以是线性相关的, 也可以是线性无关的。在矩阵列向量的所有子集中线性无关向量组所包含

向量个数的最大值，我们称之为**秩**（**rank**）。比如对于矩阵

$$A = \begin{bmatrix} 1 & 1 & 2 & 0 \\ 0 & 2 & 3 & 5 \end{bmatrix}$$

其所有四个向量是线性相依的，任意三个列向量也都是线性相依的，而前两个列向量是线性无关的，因而其矩阵的秩为 2，我们记为  $\text{rank}(A) = 2$ 。矩阵的秩有如下的性质：

1.  $\text{rank}(A_{n \times k}) \leq \min(n, k)$
2.  $\text{rank}(A) = \text{rank}(A') = \text{rank}(A'A) = \text{rank}(AA')$
3. 若  $A$  为  $n \times k$  的矩阵，而  $B$  为  $k \times k$  的矩阵，且  $\text{rank}(B) = k$ ，那么  $\text{rank}(AB) = \text{rank}(A)$
4.  $\text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$

对于方阵，如果其秩等于行（列）数，那么我们称其为**满秩**（**full rank**）矩阵。如果方阵  $A$  满足  $A = A'$ ，那么我们称其为**对称矩阵**（**symmetric matrix**）。如果一个方阵其非对角线元素都为 0，那么我们称其为**对角矩阵**。我们接下来会使用  $\text{diag}()$  符号将向量转化为对角阵，比如：

$$\text{diag}([1, 2, 3]) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

特别的，我们令  $I = \text{diag}(1)$  为对角线元素都为 1 的对角阵，称为**单位阵**（**identity matrix**）。

此外，如果一个方阵  $A$  满足  $AA' = A'A = I$ ，那么我们称  $A$  为**正交矩阵**（**orthogonal matrix**）。实际上，如果将矩阵  $A$  看成是列向量的组合， $A = [a_1, \dots, a_n]$ ，那么：

$$A'A = \begin{bmatrix} a'_1 \\ \vdots \\ a'_n \end{bmatrix} [a_1, \dots, a_n] = \begin{bmatrix} a'_1 a_1 & \cdots & a'_1 a_n \\ \vdots & \ddots & \vdots \\ a'_n a_1 & \cdots & a'_n a_n \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

意味着  $A$  的列向量其范数都等于 1，且两两正交。显然，单位阵满足上述条件，为正交矩阵。

对于方阵  $A_{n \times n}$ ，我们可以定义其行列式（determinant）：

$$|A| = \sum (-1)^{\phi(j_1, \dots, j_n)} \prod_{i=1}^n a_{ij_i}$$

其中  $(j_1, \dots, j_n)$  为  $(1, \dots, n)$  的排列 (permutations), 而  $\phi(j_1, \dots, j_n)$  为  $(1, \dots, n)$  变换到  $(j_1, \dots, j_n)$  所需要交换的次数。实际上, 矩阵的行列式与面积、体积紧密相关, 比如, 对于一个  $2 \times 2$  的矩阵:

$$A = \begin{bmatrix} 1 & 3 \\ 2 & 1 \end{bmatrix}$$

其行列式的绝对值等于以  $(0, 0), (1, 2), (3, 1)$  为顶点的矩形的面积 (或者三角形面积的两倍)。如果方阵为不满秩, 即矩阵的某一列可以被其他列向量表示出, 那么其「体积」等于 0, 因而其行列式等于 0。对于此类矩阵, 我们称之为**奇异阵** (singular matrix)。行列式有以下性质:

- $|AB| = |A| |B|$
- $|A'| = |A|$
- $|\alpha A| = \alpha^n |A|$

此外, 对于方阵, 我们还可以定义**迹** (trace), 即对角线元素的和:

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}$$

矩阵的迹有如下结论:

- $\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$
- $\text{tr}(\lambda A) = \lambda \text{tr}(A)$
- $\text{tr}(A') = \text{tr}(A)$
- $\text{tr}(AB) = \text{tr}(BA)$

此外, 显然对于一个标量 ( $1 \times 1$ ), 其迹的值就等于他本身。我们可以使用迹的概念定义一个矩阵的范数:

$$\|A\| = \sqrt{\text{tr}(A'A)} = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}$$

如果  $\|A - B\| = 0$  那么  $A = B$ 。

最后, 对于方阵, 如果其行列式不等于 0, 即非奇异矩阵, 那么可以定义其逆矩阵 (inverse matrix)。对于一个  $n \times n$  的非奇异矩阵, 如果矩阵  $B$  满足:

$$AB = BA = I$$

那么我们称矩阵  $B$  为矩阵  $A$  的逆矩阵, 记为  $B = A^{-1}$ 。对于逆矩阵, 有:

- $(A^{-1})' = (A')^{-1}$
- $(AB)^{-1} = B^{-1}A^{-1}$
- $|A^{-1}| = |A|^{-1}$
- 若  $A$  为  $n \times n$  的非奇异矩阵, 且:

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}$$

其中  $A_{11}$  为  $r \times r$  的非奇异矩阵,  $A_{22}$  为  $k \times k$  的方阵,  $A_{12}$  为  $r \times k$  的矩阵, 令  $D = A_{22} - A_{21}A_{11}^{-1}A_{12}$ , 且  $D$  也是非奇异矩阵, 那么:

$$A^{-1} = \begin{bmatrix} A_{11}^{-1} + A_{11}^{-1}A_{12}D^{-1}A_{21}A_{11}^{-1} & -A_{11}^{-1}A_{12}D^{-1} \\ -D^{-1}A_{21}A_{11}^{-1} & D^{-1} \end{bmatrix}$$

或者令  $E = A_{11} - A_{12}A_{22}^{-1}A_{21}$ , 且  $E$  也是非奇异矩阵, 那么:

$$A^{-1} = \begin{bmatrix} E^{-1} & -E^{-1}A_{12}A_{22}^{-1} \\ -A_{22}^{-1}A_{21}E^{-1} & A_{22}^{-1} + A_{22}^{-1}A_{21}E^{-1}A_{12}A_{22}^{-1} \end{bmatrix}$$

对于任意两个矩阵  $A_{m \times n}$  和  $B_{p \times q}$ , 我们还可以定义其 Kronecker 乘积:

$$A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \cdots & a_{1n}B \\ a_{21}B & a_{22}B & \cdots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1}B & a_{n2}B & \cdots & a_{nn}B \end{bmatrix}$$

即得到了一个  $mp \times nq$  的矩阵。此外, 我们还可以定义  $\text{vec}()$  操作符。对于一个  $n \times k$  矩阵  $A = [a_1, \dots, a_k]$ , 那么

$$\text{vec}(A) = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_k \end{bmatrix}$$

即得到了一个  $nk \times 1$  的向量。Kronecker 乘积和  $\text{vec}()$  操作符有如下性质:

- $A \otimes B \otimes C = (A \otimes B) \otimes C = A \otimes (B \otimes C)$
- $(A + B) \otimes (C + D) = A \otimes C + A \otimes D + B \otimes C + B \otimes D$
- $(A \otimes B) \otimes (C \otimes D) = AC \otimes BD$  如果  $AC$ 、 $BD$  存在

- $\alpha \otimes A = \alpha A = A \otimes \alpha$
- 对于两个向量  $a, b$ ,  $a' \otimes b = ba' = b \otimes a'$
- $(A \otimes B)' = A' \otimes B'$
- $\text{tr}(A \otimes B) = \text{tr}(A) \text{tr}(B)$
- $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$
- $\text{rank}(A \otimes B) = \text{rank}(A) \text{rank}(B)$
- 对于向量  $a$ ,  $\text{vec}(a') = \text{vec}(a) = a$
- 对于两个向量  $a, b$ ,  $\text{vec}(ab') = b \otimes a$
- $\text{vec}(A)' \text{vec}(B) = \text{tr}(A'B)$
- $\text{vec}(ABC) = (C' \otimes A) \text{vec}(B)$
- $\text{tr}(ABCD) = (\text{vec}(D'))' (C' \otimes A) \text{vec}(B) = (\text{vec}(D'))' (A \otimes C') \text{vec}(B')$

## 2 线性空间与线性变换

如果我们将矩阵  $A$  左乘一个  $n$  维向量  $x$ , 那么  $y = Ax$  为一个  $k$  维向量。现在我们可以把矩阵左乘向量视为一个函数, 即  $y = A(x) = Ax$ , 易知  $A(x_1 + x_2) = Ax_1 + Ax_2$ , 以及  $A(\alpha x) = \alpha Ax$ , 我们一般把符合如上两个性质的函数成为**线性映射** (**linear mapping**)。特别的, 当  $k = n$ , 即  $A$  为  $n \times n$  维方阵时, 线性映射  $A$  将  $\mathbb{R}^n$  上的一个向量  $x$  映射到  $\mathbb{R}^n$  上的另外一个向量  $y$ , 此时我们称  $A$  为**线性变换** (**linear transformation**)。比如变换:

$$A = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix}$$

就将一个二维空间  $\mathbb{R}^2$  上的向量逆时针旋转  $\theta$  度。取  $\theta = \frac{\pi}{2}$ , 那么:

$$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

取  $x = [1, 0]'$ , 那么  $y = Ax = [0, 1]'$ , 逆时针旋转了 90 度。

使用分块矩阵, 如果令  $x = [x_1, x_2, \dots, x_n]' \in \mathbb{R}^n$ ,  $A_{k \times n} = [a_1, \dots, a_n]$ , 其中  $a_i$  为  $k$  维列向量, 那么:

$$y = Ax = [a_1, \dots, a_n] \cdot \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \sum_{i=1}^n x_i a_i$$

也就是说线性映射的结果  $y$  实际上是矩阵  $A$  的列向量  $a_i$  的一个线性组合。因而矩阵  $A$  的秩  $\text{rank}(A)$ ，即矩阵  $A$  的列向量的极大线性无关组，也就是对于所有  $x \in \mathbb{R}^n$ ，所有  $y = Ax$  的极大线性无关组，或者所有向量  $\{y = Ax, \forall x \in \mathbb{R}^n\}$  这个线性空间的维数。

### 3 线性型与二次型

对于任何一个向量  $x \in \mathbb{R}^n$ ，**线性型** (linear form) 即一个关于  $x$  的线性函数  $f(x): \mathbb{R}^n \rightarrow \mathbb{R}$ :

$$f(x) = a_1x_1 + \cdots + a_nx_n = a'x$$

其中:

$$a = \begin{bmatrix} a_1 \\ \vdots \\ a_n \end{bmatrix}$$

而**二次型** (quadratic form) 则是一个关于  $x$  的二次函数  $g(x): \mathbb{R}^n \rightarrow \mathbb{R}$ :

$$\begin{aligned} g(x) &= a_{11}x_1^2 + a_{12}x_1x_2 + \cdots + a_{1n}x_1x_n + a_{21}x_2x_1 + \cdots + a_{nn}x_n^2 \\ &= \sum_{i=1}^n \sum_{j=1}^n a_{ij}x_ix_j \\ &= x'Ax \end{aligned}$$

其中:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

不失一般性，我们一般将以上二次型写成一个对称矩阵的形式，即假定  $A$  为一个实对称矩阵。

对于一个方阵  $A_{n \times n}$ ，如果一个向量  $v \in \mathbb{R}^n$  满足:

$$Av = \lambda v$$

那么我们称  $v$  为  $A$  的一个**特征向量** (eigenvector)，而  $\lambda$  则称为一个**特征值** (eigenvalue)。如果我们将矩阵  $A$  看做是一个线性变换，那么特征向量即经过  $A$  的变换以后，保持方向不变的向量。实际上，如果  $v$  是  $A$  的一个特征向量，那么将其乘以一个常数  $c$ ， $cv$  也满足： $Acv = cAv = c\lambda v = \lambda cv$ ，因而  $cv$  也是矩阵  $A$  的一个特征向量。



如果矩阵  $A_{n \times n}$  有  $n$  个线性独立的特征向量:  $\{v^1, \dots, v^n\}$ , 其对应的特征值为:  $\{\lambda_1, \dots, \lambda_n\}$ , 记矩阵:

$$\Gamma = \begin{bmatrix} v^1 & \dots & v^n \end{bmatrix}^{-1}$$

那么矩阵  $A$  可以被分解为:

$$A = \Gamma^{-1} \text{diag}([\lambda_1, \dots, \lambda_n]) \Gamma \triangleq \Gamma^{-1} \Lambda \Gamma$$

以上分解我们称之为**特征分解** (eigendecomposition)。根据行列式的性质, 我们有:

$$|A| = |\Gamma^{-1} \Lambda \Gamma| = |\Gamma^{-1}| |\Lambda| |\Gamma| = |\Lambda| = \prod_{i=1}^n \lambda_i$$

而根据迹的性质, 有:

$$\text{tr}(A) = \text{tr}(\Gamma^{-1} \Lambda \Gamma) = \text{tr}(\Lambda \Gamma \Gamma^{-1}) = \text{tr}(\Lambda) = \sum_{i=1}^n \lambda_i$$

注意并非任何一个方阵  $A$  都可以进行特征分解, 不过有一类特殊的矩阵, 即实对称矩阵, 必然可以被特征分解, 且矩阵  $\Gamma$  可以变换为一个正交矩阵。由于正交矩阵的逆矩阵等于其对称矩阵, 因而实对称矩阵  $A$  总是可以被分解为如下形式:

$$A = \Gamma' \Lambda \Gamma$$

其中  $\Gamma$  为正交矩阵。

由于正交矩阵  $\Gamma' \Gamma = I$ , 因而矩阵  $\Gamma$  的列向量 (**特征向量**, eigenvector) 是两两正交的, 且每个列向量的范数为 1。比如矩阵:

$$\Gamma = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix}$$

为正交矩阵, 其每个列向量都是正交的且范数为 1。这类矩阵对应着等距变换 (isometry), 即两个点经过正交矩阵  $\Gamma$  的变换之后,  $d(\Gamma x, \Gamma y) = \sqrt{x' \Gamma' \Gamma y} = \sqrt{x' y} = d(x, y)$ 。正交矩阵对应着旋转、翻转等变换; 而相应的, 对角矩阵  $\Lambda$  则对应着在不同的方向上的拉伸变换。因而实对称矩阵的特征值分解将一个线性变换  $A$  分解为了一个等距变换  $\Gamma$  和一个放缩变换  $\Lambda$ 。

如果对于任何一个向量  $x \in \mathbb{R}^n$ , 二次型  $x' A x > 0$ , 我们称矩阵  $A$  为**正定矩阵** (Positive-definite matrix); 如果满足  $x' A x \geq 0$ , 则成为**半正定矩阵** (Positive semi-definite matrix); 负定矩阵和半负定矩阵可以类似定义。

对于一个实对称矩阵  $A$ , 其二次型:

$$x' A x = x' \Gamma' \Lambda \Gamma x = (\Gamma x)' \Lambda (\Gamma x)$$

注意由于  $y = \Gamma x$  为一个  $n$  维向量，因而上式可以写为：

$$x'Ax = y'\Lambda y = \sum_{i=1}^n \lambda_i y_i^2 > 0 (\geq 0)$$

因而如果实对称矩阵  $A$  的所有特征值都  $> 0$  ( $\geq 0$ )，那么这个矩阵为正定矩阵 (半正定矩阵)。

## 4 投影与幂等矩阵

在实对称矩阵中，有一类矩阵是我们接下来非常频繁使用的，即**幂等矩阵** (**Idempotent matrix**)。如果一个方阵  $P$  满足  $P^2 = P$ ，那么我们称矩阵  $P$  为幂等矩阵。例如，矩阵：

$$P = \frac{1}{4} \cdot \begin{bmatrix} -4 & 6 & 2 \\ -12 & 13 & 3 \\ 20 & -15 & -1 \end{bmatrix}$$

为幂等矩阵，可以验证  $P^2 = P$ 。

特别的，当  $P$  为实对称矩阵时，我们称其为**投影矩阵** (**Projection matrix**)。由于所有实对称矩阵都可以被对角化，所以对于任意的投影矩阵，都可以写为：

$$P = \Gamma' \Lambda \Gamma$$

而由于  $P^2 = \Gamma' \Lambda \underbrace{\Gamma \Gamma'}_I \Lambda \Gamma = \Gamma' \Lambda^2 \Gamma = \Gamma' \Lambda \Gamma$ ，且  $\Gamma$  为可逆矩阵，所以  $\Lambda^2 = \Lambda$ 。

由于  $\Lambda$  为对角阵，所以  $\Lambda$  的对角元必为 0 或者 1。因而  $\text{rank}(P) = \text{rank}(\Lambda) = \text{tr}(\Lambda)$ 。

投影矩阵顾名思义，与**投影** (**Projection**) 的概念密不可分。如果把投影矩阵  $P$  视为线性变换，幂等矩阵的定义意味着一个向量经过  $P$  的变换以后，再次经过  $P$  的变换仍然保持不变，即  $P(Px) = P^2x = Px$ 。比如矩阵：

$$P = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

即把一个  $x-y-z$  三维坐标系中的一个向量  $x = (x_1, x_2, x_3)'$  映射到  $x-y$  二维平面上的点  $Px$ ，而一个本身就在  $x-y$  二维平面的点，如  $Px$ ，再次经过  $P$  的映射，还是在  $x-y$  二维平面上，且就是其本身。可以验证， $P^2 = P$ 。类似的，矩阵：

$$P = \begin{bmatrix} 0.5 & 0.5 & 0 \\ 0.5 & 0.5 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

则把一个三维向量  $x = (x_1, x_2, x_3)'$  映射到  $y = x$  这条直线上, 同样有  $P^2 = P$ 。

如果定义  $M = I - P$ , 那么  $M^2 = (I - P)(I - P) = I - P - P + P^2 = I - P = M$ , 即  $M = I - P$  也为投影矩阵。注意  $(Mx)'Px = x'(I - P)Px = x'(P - P^2)x = 0$ , 因而  $Px$  与  $Mx$  是正交的。也就是说, 幂等矩阵把一个向量  $x$  分解成了正交的两个部分:  $Px$  和  $Mx$ ,  $x = Px + Mx$  且  $\langle Mx, Px \rangle = 0$ 。

**例 1.** 令  $\iota \in \mathbb{R}^n, \iota = (1, 1, \dots, 1)'$ , 那么矩阵  $P_0 = \frac{1}{n}\iota\iota'$  为投影矩阵, 即  $P_0' = P_0$ , 且  $P_0^2 = \frac{1}{n^2}\iota \underbrace{\iota'\iota}_n \iota' = \frac{1}{n}\iota\iota' = P_0$ 。对于一个向量  $x$ ,

$$P_0x = \frac{1}{n}\iota\iota'x = \frac{1}{n}\iota \cdot \sum_{i=1}^n x_i = \iota \cdot \bar{x} = \begin{pmatrix} \bar{x} \\ \vdots \\ \bar{x} \end{pmatrix}$$

即  $P_0$  将一个向量投影变换为其均值向量。易知  $\text{rank}(P_0) = \text{tr}(P_0) = \text{tr}(\frac{1}{n}\iota\iota') = \frac{1}{n}\text{tr}(\iota'\iota) = 1$ 。如果令  $M_0 = I - P_0$ , 根据上述结论, 易知  $M_0$  也是幂等矩阵, 且  $\text{rank}(M_0) = \text{tr}(M_0) = \text{tr}(I - P_0) = \text{tr}(I) - \text{tr}(P_0) = n - 1$ , 且:

$$M_0x = x - \frac{1}{n}\iota\iota'x = \begin{pmatrix} x_1 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{pmatrix}$$

那么:

$$\sum_{i=1}^n (x_i - \bar{x})^2 = (M_0x)'M_0x = x'M_0x$$

为一个二次型的形式。

## 5 矩阵微积分

对于一个向量  $\theta = [\theta_1, \theta_2, \dots, \theta_n]'$ , 其实值函数:  $f(\theta) : \mathbb{R}^n \rightarrow \mathbb{R}$ , 我们可以定义函数  $f(\cdot)$  对向量  $\theta$  的导数为:

$$\frac{\partial f}{\partial \theta} = \begin{bmatrix} \frac{\partial f}{\partial \theta_1} \\ \frac{\partial f}{\partial \theta_2} \\ \vdots \\ \frac{\partial f}{\partial \theta_n} \end{bmatrix}$$

同时定义其二阶导：

$$\frac{\partial^2 f}{\partial \theta \partial \theta'} = \begin{bmatrix} \frac{\partial^2 f}{\partial \theta_1^2} & \frac{\partial^2 f}{\partial \theta_1 \partial \theta_2} & \cdots & \frac{\partial^2 f}{\partial \theta_1 \partial \theta_n} \\ \frac{\partial^2 f}{\partial \theta_2 \partial \theta_1} & \frac{\partial^2 f}{\partial \theta_2^2} & \cdots & \frac{\partial^2 f}{\partial \theta_2 \partial \theta_d} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial \theta_n \partial \theta_1} & \frac{\partial^2 f}{\partial \theta_n \partial \theta_2} & \cdots & \frac{\partial^2 f}{\partial \theta_n^2} \end{bmatrix}$$

比如，如果  $f(\theta) = \frac{\mu^2}{2\sigma^2} + \ln(\sigma)$ ， $\theta = (\mu, \sigma)'$  那么：

$$\frac{\partial f(\theta)}{\partial \theta} = \begin{bmatrix} \frac{\mu}{\sigma^2} \\ \frac{1}{\sigma} - \frac{\mu^2}{\sigma^3} \end{bmatrix}$$

$$\frac{\partial^2 f(\theta)}{\partial \theta \partial \theta'} = \begin{bmatrix} \frac{1}{\sigma^2} & -\frac{2\mu}{\sigma^3} \\ -\frac{2\mu}{\sigma^3} & \frac{3\mu^2}{\sigma^4} - \frac{1}{\sigma^2} \end{bmatrix}$$

我们知道对于一个实值函数， $\frac{\partial^2 f}{\partial \theta_i \partial \theta_j} = \frac{\partial^2 f}{\partial \theta_j \partial \theta_i}$ ，因而  $\frac{\partial^2 f}{\partial \theta \partial \theta'}$  是一个实对称矩阵。回忆极值原理，如果函数  $f$  可微，那么函数  $f$  在  $\theta_0$  处为极值点的必要条件是  $\frac{\partial f(\theta_0)}{\partial \theta} = 0$ ，如果  $\frac{\partial^2 f(\theta_0)}{\partial \theta \partial \theta'}$  为正定矩阵（ $f(\theta)$  的所有特征值为正），那么  $f$  在  $\theta_0$  处为极小值点，否则如果  $\frac{\partial^2 f(\theta_0)}{\partial \theta \partial \theta'}$  为负定矩阵（ $f(\theta)$  的所有特征值为负），那么  $f$  在  $\theta_0$  处为极大值点，如果  $\frac{\partial^2 f(\theta_0)}{\partial \theta \partial \theta'}$  的特征值既有正值又有负值，那么  $f$  在  $\theta_0$  处为鞍点（saddle point）。我们称  $\frac{\partial^2 f(\theta)}{\partial \theta \partial \theta'}$  为**海塞矩阵**（**Hessian matrix**）。

**例 2.** 记向量  $x = (x_1, x_2)'$ ，效用函数为  $f(x) = \ln x_1 + \ln x_2$ 。为了求解如下效用最大化问题：

$$\begin{aligned} \max_x & f(x) \\ \text{s.t.} & p'x = I \end{aligned}$$

其中  $p = (p_1, p_2)'$  为价格， $I$  为收入，可以构造拉格朗日函数：

$$\mathcal{L}(x, \lambda; p, I) = \ln x_1 + \ln x_2 + \lambda(I - p'x)$$

其一阶条件为：

$$\frac{\partial \mathcal{L}(x, \lambda; p, I)}{\partial x} = \begin{pmatrix} \frac{1}{x_1} \\ \frac{1}{x_2} \end{pmatrix} - \lambda \begin{pmatrix} p_1 \\ p_2 \end{pmatrix} = 0$$

解得：

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} \frac{I}{2p_1} \\ \frac{I}{2p_2} \end{pmatrix}$$

在所有向量的实值函数中，有两类函数是非常常用的，即线性型以及二次

型。对于线性型：  $f(\theta) = \alpha'\theta$ ，其一阶导数为：

$$\frac{\partial \alpha'\theta}{\partial \theta} = \alpha$$

而二次型  $g(\theta) = \theta' A \theta$  的一阶导数为：

$$\frac{\partial (\theta' A \theta)}{\partial \theta} = A\theta + A'\theta = (A + A')\theta$$

而其二阶导为：

$$\frac{\partial^2 \theta' A \theta}{\partial \theta \partial \theta'} = A' + A$$

特别的，如果  $A$  为对称矩阵，那么

$$\begin{aligned}\frac{\partial (\theta' A \theta)}{\partial \theta} &= 2A\theta \\ \frac{\partial^2 \theta' A \theta}{\partial \theta \partial \theta'} &= 2A\end{aligned}$$

**例 3.** 如果存在  $n$  个有价证券，其期望收益率向量为  $r = [r_1, \dots, r_n]$ ，而其收益率的协方差矩阵为  $\Sigma$ 。现在给定一个权重向量  $x$ ，满足  $x'\iota = 1$ ，即所有权重相加等于 1，那么根据权重向量配置  $n$  个有价证券，我们就得到了一个资产组合，该资产组合的期望收益率为  $x'r$ ，而资产组合收益率的方差为  $x'\Sigma x$ 。在所有的资产组合中，有一个资产组合其方差最小，为了求出这个使得方差最小的资产组合权重，我们可以解如下问题：

$$\begin{aligned} & \min_x x'\Sigma x \\ \text{s.t.} \quad & x'\iota = 1 \end{aligned}$$

构建拉格朗日函数<sup>1</sup>：

$$\mathcal{L}(x, \lambda; r, \Sigma) = x'\Sigma x + 2\lambda(1 - x'\iota)$$

其一阶条件为：

$$\frac{\partial \mathcal{L}(x, \lambda; p, I)}{\partial x} = 2\Sigma x - 2\lambda\iota = 0$$

解得：

$$x = \lambda \Sigma^{-1} \iota$$

将其带入约束中，得到：

$$\lambda \iota' \Sigma^{-1} \iota = 1$$

---

<sup>1</sup>为了方便起见，不失一般性，我们令拉格朗日乘子为  $2\lambda$ 。

从而：

$$\lambda = \frac{1}{\iota' \Sigma^{-1} \iota}$$

最终我们得到权重向量：

$$x = \frac{\Sigma^{-1} \iota}{\iota' \Sigma^{-1} \iota}$$

## 习题

1. 证明：

$$(a) \ Ax = 0 \iff A'Ax = 0$$

$$(b) \ AB = 0 \iff A'AB = 0$$

$$(c) \ A'AB = A'AC \iff AB = AC$$

2. 在例 (3) 中，如果投资者的效用函数为：

$$U(x; r, \Sigma) = x'r - \gamma x' \Sigma x$$

其中  $\gamma \geq 0$  为一个标量，度量了投资者的风险厌恶程度，请求出使得效用最大化的资产组合权重  $x$ 。

3. 同样在例 (3) 中，请计算给定投资组合期望收益  $x'r = r^*$  的条件下，方差最小的投资组合权重  $x$ 。