

# 系统估计与面板数据

司继春

上海对外经贸大学统计与信息学院

在之前一章中，我们学习了在外生性条件下单方程的最小二乘估计问题。在这一节中，我们将主要介绍最小二乘法在多方程条件下的推广。而在这其中，整群抽样以及面板数据是最经常使用的两个例子，我们将重点介绍这些模型。

## 1 系统最小二乘

在此之前我们学习了单方程的线性回归问题，如果记  $y_i$  为被解释变量， $x_i$  为解释变量向量，假设两者存在如下线性关系：

$$y_i = x_i' \beta + u_i$$

那么在外生性条件  $\mathbb{E}(u_i|x_i) = 0$  的条件下，可以使用普通最小二乘（OLS）对参数  $\beta$  进行估计。

然而在实际应用中，我们可能会碰到对于每个个体，同时存在不止一个方程需要估计的情况。其中，**似不相关回归**（seemingly unrelated regression）和面板数据模型是最经常遇到的两类需要同时估计多个方程的模型。

**例 1.**（似不相关回归）如果我们关心家庭的消费支出问题，对于每一个家庭  $i$ ，我们可以观察到其不同种类的支出占收入的比例，比如我们考虑食品支出比例（ $y_i^F$ ）、医疗支出比例（ $y_i^M$ ）以及教育支出比例（ $y_i^E$ ），每一类支出都是由不同的价格水平及收入决定的：

$$y_i^j = \beta_j + \beta_j^F p_F + \beta_j^M p_M + \beta_j^E p_E + \beta_j^I I + u_i^j = x_i' \beta^j + u_i^j, j = F, M, E \quad (1)$$

其中  $x_i$  为  $K \times 1$  维的由价格水平  $p_j$  和收入  $I$  所组成的解释向量。我们可以将以上模型用向量的形式表达，记：

$$Y_i = \begin{bmatrix} y_i^F \\ y_i^M \\ y_i^E \end{bmatrix}$$

以及:

$$X_i = \begin{bmatrix} x'_i & 0 & 0 \\ 0 & x'_i & 0 \\ 0 & 0 & x'_i \end{bmatrix}_{3 \times 5}, \beta = \begin{bmatrix} \beta^F \\ \beta^M \\ \beta^E \end{bmatrix}_{15 \times 1}, U_i = \begin{bmatrix} u_i^F \\ u_i^M \\ u_i^E \end{bmatrix}$$

从而我们可以将式 (1) 联合写为:

$$Y_i = X_i \beta + U_i = \begin{bmatrix} x'_i & 0 & 0 \\ 0 & x'_i & 0 \\ 0 & 0 & x'_i \end{bmatrix} \begin{bmatrix} \beta^F \\ \beta^M \\ \beta^E \end{bmatrix} + \begin{bmatrix} u_i^F \\ u_i^M \\ u_i^E \end{bmatrix}$$

在这里, 对于每一个个体  $i$ , 我们都有三个方程需要同时进行估计。

**例 2.** (面板数据) 如果我们可以对同一个个体在不同时间点上重复观测多次, 我们就得到了一个面板数据。令  $t = 1, 2, \dots, T$  代表时间, 且每期都有回归方程:

$$y_{it} = x'_{it} \beta + u_{it} \quad (2)$$

我们同样可以将以上方程使用向量表示。令:

$$Y_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ \vdots \\ y_{iT} \end{bmatrix}_{T \times 1}$$

以及:

$$X_i = \begin{bmatrix} x'_{i1} \\ x'_{i2} \\ \vdots \\ x'_{iT} \end{bmatrix}_{T \times K}, U_i = \begin{bmatrix} u'_{i1} \\ u'_{i2} \\ \vdots \\ u'_{iT} \end{bmatrix}_{T \times 1}$$

那么对于每一个个体  $i$ , 我们都有  $T$  个方程, 此时方程 (2) 可以表示为:

$$Y_i = X_i \beta + U_i = \begin{bmatrix} x'_{i1} \\ x'_{i2} \\ \vdots \\ x'_{iT} \end{bmatrix} \beta + \begin{bmatrix} u_{i1} \\ u_{i2} \\ \vdots \\ u_{iT} \end{bmatrix}$$

注意在这里我们假设了在每一期,  $x_{it}$  对  $y_{it}$  的影响都是相同的, 其系数都是  $\beta$ 。

在以上两个例子中, 我们所面临的问题都是相似的, 对于每一个个体, 我们都有  $J$  个方程需要同时进行估计: 在例 (1) 中, 我们需要同时估计三个产品的

需求,而在例 (2) 中,我们需要同时估计同一个个体  $T$  期的方程。在每种情况下,我们都可以将问题转化为以下形式:

$$Y_i = X_i\beta + U_i \quad (3)$$

与一元线性回归不同的是,这里对于每一个个体,  $Y_i$  和  $U_i$  都是  $J \times 1$  的向量,而  $X_i$  为  $J \times K$  的矩阵。

实际上,如果我们假设  $\mathbb{E}(u_{ij}|x_{ij}) = 0$ ,那么我们可以对第  $j$  个方程做普通最小二乘估计,就可以得到对于  $\beta_j$  的一致估计。然而很多时候,同时估计  $J$  个方程可以带来额外的好处。比如,某些时候我们希望对跨方程的约束进行检验,例如在例 (1) 中,我们可能需要对  $H_0: \beta_E^F = \beta_F^E$  进行假设检验,如果将三个方程单独估计,那么我们无法获得两个系数  $\beta_E^F, \beta_F^E$  的协方差,因而无法完成假设检验。或者,在例 (2) 中,我们假设了每一期  $x_{it}$  对  $y_{it}$  的影响都是相同的,如果单独每一期进行回归,那么我们会得到每一期都有不同的  $\beta_t$ ,而如果联合估计多期的方程,可以潜在的提高估计的有效性。

对于方程 (3),在  $\mathbb{E}(u_{ij}|x_{ij}) = 0$  满足的条件下,我们有:  $\mathbb{E}(u_{ij}x_i) = 0$ 。如果对于每一个  $j = 1, \dots, J$ , 该条件都成立,那么我们可以将以上条件写为:

$$\mathbb{E}(X_i'U_i) = \mathbb{E}[X_i'(Y_i - X_i\beta)] = 0$$

从而得到:

$$\beta = [\mathbb{E}(X_i'X_i)]^{-1} [\mathbb{E}(X_i'Y_i)]$$

使用样本矩代替总体矩,我们便得到了  $\beta$  的矩估计:

$$\hat{\beta} = \left[ \frac{1}{N} \sum_{i=1}^N (X_i'X_i) \right]^{-1} \left[ \frac{1}{N} \sum_{i=1}^N (X_i'Y_i) \right] = \left[ \sum_{i=1}^N (X_i'X_i) \right]^{-1} \left[ \sum_{i=1}^N (X_i'Y_i) \right]$$

以上估计称为**系统普通最小二乘估计**(system ordinary least squares, SOLS)。

**例 3.** 在例 (1) 中,带入以上公式,我们得到:

$$\sum_{i=1}^N (X_i'X_i) = \sum_{i=1}^N \begin{bmatrix} x_i & 0 & 0 \\ 0 & x_i & 0 \\ 0 & 0 & x_i \end{bmatrix} \begin{bmatrix} x_i' & 0 & 0 \\ 0 & x_i' & 0 \\ 0 & 0 & x_i' \end{bmatrix} = \sum_{i=1}^N \begin{bmatrix} x_i x_i' & 0 & 0 \\ 0 & x_i x_i' & 0 \\ 0 & 0 & x_i x_i' \end{bmatrix}$$

同时:

$$\sum_{i=1}^N (X_i'Y_i) = \sum_{i=1}^N \begin{bmatrix} x_i & 0 & 0 \\ 0 & x_i & 0 \\ 0 & 0 & x_i \end{bmatrix} \begin{bmatrix} y_i^F \\ y_i^M \\ y_i^E \end{bmatrix} = \sum_{i=1}^N \begin{bmatrix} x_i y_i^F & 0 & 0 \\ 0 & x_i y_i^M & 0 \\ 0 & 0 & x_i y_i^E \end{bmatrix}$$

从而该模型的 SOLS 估计量为:

$$\begin{aligned} \begin{bmatrix} \hat{\beta}^F \\ \hat{\beta}^M \\ \hat{\beta}^E \end{bmatrix} &= \left( \sum_{i=1}^N \begin{bmatrix} x_i x_i' & 0 & 0 \\ 0 & x_i x_i' & 0 \\ 0 & 0 & x_i x_i' \end{bmatrix} \right)^{-1} \left( \sum_{i=1}^N \begin{bmatrix} x_i y_i^F & 0 & 0 \\ 0 & x_i y_i^M & 0 \\ 0 & 0 & x_i y_i^E \end{bmatrix} \right) \\ &= \begin{bmatrix} \left( \sum_{i=1}^N x_i x_i' \right)^{-1} \sum_{i=1}^N x_i y_i^F \\ \left( \sum_{i=1}^N x_i x_i' \right)^{-1} \sum_{i=1}^N x_i y_i^M \\ \left( \sum_{i=1}^N x_i x_i' \right)^{-1} \sum_{i=1}^N x_i y_i^E \end{bmatrix} = \begin{bmatrix} \beta_{OLS}^F \\ \beta_{OLS}^M \\ \beta_{OLS}^E \end{bmatrix} \end{aligned}$$

因而在该模型中, SOLS 估计与单方程分别做最小二乘估计是等价的。

**例 4.** 在例 (2) 中, 可以计算, SOLS 估计量为:

$$\hat{\beta} = \left[ \sum_{i=1}^N (X_i' X_i) \right]^{-1} \left[ \sum_{i=1}^N (X_i' Y_i) \right] = \left[ \sum_{i=1}^N \sum_{t=1}^T (x_{it} x_{it}') \right]^{-1} \left[ \sum_{i=1}^N \sum_{t=1}^T (x_{it} y_{it}) \right]$$

实际上, 以上估计等价于将所有数据放在一起做 OLS, 因而以上估计也被成为混合 OLS 估计 (pooled OLS)。

我们可以进一步建立 SOLS 的大样本性质。首先, 将式 (3) 带入, 得到:

$$\hat{\beta} = \left[ \frac{1}{N} \sum_{i=1}^N (X_i' X_i) \right]^{-1} \left[ \frac{1}{N} \sum_{i=1}^N (X_i' Y_i) \right] = \beta + \left[ \frac{1}{N} \sum_{i=1}^N (X_i' X_i) \right]^{-1} \left[ \frac{1}{N} \sum_{i=1}^N (X_i' U_i) \right]$$

对于一致性, 根据大数定律, 在一定条件下, 有:

$$\frac{1}{N} \sum_{i=1}^N (X_i' X_i) \xrightarrow{p} \mathbb{E} (X_i' X_i) \triangleq A$$

以及:

$$\frac{1}{N} \sum_{i=1}^N (X_i' U_i) = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^J x_{ij} u_{ij} \xrightarrow{p} \mathbb{E} \sum_{j=1}^J x_{ij} u_{ij} = 0$$

从而得到:  $\hat{\beta} \xrightarrow{p} \beta$ , 即 SOLS 是一致估计量。

而对于渐进分布, 由于:

$$\text{Var} (X_i' U_i) = \mathbb{E} (X_i' U_i U_i' X_i) \triangleq B$$

根据中心极限定理, 在一定的条件下, 有:

$$\frac{1}{\sqrt{N}} \sum_{i=1}^N (X_i' U_i) \stackrel{a}{\sim} N(0, B)$$

因而：

$$\sqrt{N}(\hat{\beta} - \beta) \stackrel{a}{\sim} N(0, A^{-1}BA^{-1})$$

以上即 SOLS 的大样本分布。

在实践中，我们需要对  $A$  和  $B$  两个矩阵进行估计。对于矩阵  $A$ ，可以使用  $\frac{1}{N} \sum_{i=1}^N (X_i' X_i)$  直接进行估计，而对于矩阵  $B$ ，可以令残差向量：

$$\hat{U}_i = Y_i - X_i' \hat{\beta}$$

从而可以矩阵  $B$  可以使用  $\frac{1}{N} \sum_{i=1}^N (X_i' \hat{U}_i \hat{U}_i' X_i)$  进行估计。最终， $\hat{\beta}$  的渐进方差可以使用：

$$\begin{aligned} \widehat{\text{Var}}(\hat{\beta}) &= \frac{1}{N} \left[ \frac{1}{N} \sum_{i=1}^N (X_i' X_i) \right]^{-1} \left[ \frac{1}{N} \sum_{i=1}^N (X_i' \hat{U}_i \hat{U}_i' X_i) \right] \left[ \frac{1}{N} \sum_{i=1}^N (X_i' X_i) \right]^{-1} \\ &= \left[ \sum_{i=1}^N (X_i' X_i) \right]^{-1} \left[ \sum_{i=1}^N (X_i' \hat{U}_i \hat{U}_i' X_i) \right] \left[ \sum_{i=1}^N (X_i' X_i) \right]^{-1} \end{aligned}$$

进行估计。

在有了渐进正态性之后，对于任意的关于  $\beta$  的原假设，都可以使用 Wald 检验以及 delta 方法构建检验统计量。

## 2 广义最小二乘

以上我们构建了多方程条件下的系统最小二乘估计。然而注意在 SOLS 估计的方差中，存在着  $\mathbb{E}(X_i' U_i U_i' X_i)$  这一项，即方程之间可能存在着相关性，导致我们所得到的 SOLS 估计并不是最有效的估计。实际上，如果我们加强一些假定，可以得到更加有效的估计量。

记  $U_i$  的协方差矩阵为  $\Omega = \mathbb{E}(U_i U_i')$ ，该矩阵度量了不同方程之间  $u_{ij}$  的相关性。比如在例 (1) 中，不同之处项目的误差项之间可能存在着相关性，而在例 (2) 中，不同时间的误差项  $u_{it}$  也可能存在着相关性（这种时间上的相关性我们称之为**自相关**，**autocorrelation**）。实际上，这种相关性的存在使得 SOLS 的估计不是最有效的估计。

为了消除这种相关性，我们可以使用  $\Omega^{-1/2}$  左乘  $U_i$ ，即  $U_i^* = \Omega^{-1/2} U_i$ ，现在我们有：

$$\text{Var}(U_i^*) = \mathbb{E} \left( \Omega^{-1/2} U_i U_i' \Omega^{-1/2} \right) = \Omega^{-1/2} \mathbb{E}(U_i U_i') \Omega^{-1/2} = \Omega^{-1/2} \Omega \Omega^{-1/2} = I$$

从而得到的新的  $U_i^*$  的分量之间不再存在着相关性。

进一步，我们可以使用  $\Omega^{-1/2}$  左乘式 (3)，得到：

$$\Omega^{-1/2} Y_i = \Omega^{-1/2} X_i' \beta + \Omega^{-1/2} U_i$$

令  $Y_i^* = \Omega^{-1/2} Y_i$ ,  $X_i^* = \Omega^{-1/2} X_i$ , 我们得到了新的回归方程:

$$Y_i^* = X_i^{*'} \beta + U_i^*$$

在该方程中, 误差项  $U_i^*$  不再存在着自相关性, 因而使用以上回归方程做 OLS, 就可以得到有效的估计, 即:

$$\hat{\beta}^* = \left[ \sum_{i=1}^N (X_i^{*'} X_i^*) \right]^{-1} \left[ \sum_{i=1}^N (X_i^{*'} Y_i^*) \right] = \left[ \sum_{i=1}^N (X_i' \Omega^{-1} X_i) \right]^{-1} \left[ \sum_{i=1}^N (X_i' \Omega^{-1} Y_i) \right]$$

以上方法我们称之为**广义最小二乘** (generalized least squares, GLS)。

然而注意到, 由于:

$$\hat{\beta}^* = \left[ \sum_{i=1}^N (X_i' \Omega^{-1} X_i) \right]^{-1} \left[ \sum_{i=1}^N (X_i' \Omega^{-1} Y_i) \right] = \beta + \left[ \sum_{i=1}^N (X_i' \Omega^{-1} X_i) \right]^{-1} \left[ \sum_{i=1}^N (X_i' \Omega^{-1} U_i) \right]$$

因而为了得到一致性, 我们必须假设  $\mathbb{E}(X_i' \Omega^{-1} U_i) = 0$ , 由于  $\Omega^{-1}$  结构未知, 因而实际上我们必须假设

$$\mathbb{E}(u_{ij} x_{ih}) = 0, h = 1, \dots, J$$

即  $u_{ij}$  必须对所有方程的控制变量  $x_{ih}$  都是不相关的, 而 SOLS 则只需要  $u_{ij}$  对该方程的  $x_{ij}$  是不相关的, 即只需要假设  $\mathbb{E}(u_{ij} x_{ij}) = 0$ 。实际上, 该条件的一个充分条件是:

$$\mathbb{E}(u_{ij} | x_i) = 0$$

即  $u_{ij}$  对于所有的控制变量  $x_i = (x'_{i1}, \dots, x'_{iJ})'$  都是外生的。因而 GLS 虽然可以提高有效性, 但是代价是必须做更加严格的外生性假设。

然而现实中, 由于协方差矩阵  $\Omega$  的结构是未知的, 因而我们必须对该协方差矩阵进行估计。由于我们实际上假设了对于不同个体, 其误差项  $U_i$  的协方差矩阵都是相同的, 即所有个体的误差项的协方差矩阵都为  $\Omega = \mathbb{E}(U_i U_i')$ , 因而我们使用矩估计的方法对该协方差矩阵进行估计。由于  $\Omega$  是  $J \times J$  维的实对称矩阵, 因而为了估计  $\Omega$ , 我们必须估计  $J(J+1)/2$  个未知参数。如果  $J$  不随着  $N$  的增大而增大, 那么我们可以获得  $\Omega$  的一致估计<sup>1</sup>。

实际上, 我们可以使用:

$$\hat{\Omega} = \frac{1}{N} \sum_{i=1}^N (\hat{U}_i \hat{U}_i')$$

<sup>1</sup>该方法与单方程的加权最小二乘估计 (WLS) 是不一样的, 在 WLS 中, 每个个体的方差都是未知的, 因而我们会遇到所谓的伴生参数问题 (incidental parameters problem), 即随着样本量  $N$  的增大, 参数的维数与  $N$  同阶或者更高阶的增加, 在这种情况下不可能获得这些伴生变量的一致估计。但是在这里, 由于  $J$  不随着  $N$  的增大而增加, 因而并不存在伴生参数问题。

进行估计，而为了获得  $\hat{U}_i$ ，我们必须首先获得一个参数  $\beta$  的一致估计。因而对于方程 (3)，可以首先使用 SOLS 获得一个  $\beta$  的一致估计  $\hat{\beta}_{SOLS}$ ，然后计算残差向量：

$$\hat{U}_i = Y_i - X_i' \hat{\beta}_{SOLS}$$

最终得到  $\Omega$  的估计：

$$\hat{\Omega} = \frac{1}{N} \sum_{i=1}^N (\hat{U}_i \hat{U}_i')$$

最后使用  $\hat{\Omega}$  代替  $\Omega$ ，使用公式：

$$\hat{\beta}_{FGLS} = \left[ \sum_{i=1}^N (X_i' \hat{\Omega}^{-1} X_i) \right]^{-1} \left[ \sum_{i=1}^N (X_i' \hat{\Omega}^{-1} Y_i) \right]$$

计算广义最小二乘估计量，以上估计两被称为**可行的广义最小二乘**（feasible generalized least squares, FGLS）估计量。

## 习题